Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

УТВЕРЖДАЮ
Заведующий кафедрой ИУ7
_____ И. В. Рудаков
«__» сентября 2025 г.

ЗАДАНИЕ
на выполнение научно-исследовательской работы

по теме

Система управления корпусными данными параллельных корпусов технических текстов

Студент группы **ИУ7-74Б**

Бугаков Иван Сергеевич

Направленность НИР (учебная, исследовательская, практическая, производственная, др.): учебная.

Источник тематики (кафедра, предприятие, НИР): кафедра.

График выполнения НИР: 25% к 5 нед., 50% к 8 нед., 75% к 11 нед., 100% к 15 нед.

Техническое задание

Проанализировать предметную область использования параллельных корпусов в корпусной лингвистике. Привести классификацию корпусов текстов. Перечислить виды выравнивая и разметки текстов в параллельном корпусе. Перечислить методы построения разметки текстов в параллельном корпусе. Сформулировать критерии и сравнить перечисленные методы построения разметки применительно к параллельным корпусам технических текстов. Проанализировать и сформулировать критерии сравнения существующих систем управления корпусными данными. По сформулированным критериям провести сравнение существующих систем управления корпусными данными.

Оформление научно-исследовательской работы:

Расчетно-пояснительная записка на 12-30 листах формата А4.

Перечень графического (иллюстративного) материала:

Презентация на 3-8 слайдах.

Дата выдачи задания «__» сентября 2025 г.

Руководитель НИР _____ **Ю. В. Строганов**

Студент _____ **И. С. Бугаков**

СОДЕРЖАНИЕ

РЕФЕРАТ **3**

1 Анализ предметной области **4**

1.1 Основные понятия корпусной лингвистики 4

1.2 История развития корпусной лингвистики 5

1.3 Классификация корпусов 6

1.4 Репрезентативность корпуса 8

1.5 Виды разметок 9

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ **12**

РЕФЕРАТ

Расчетно-пояснительная записка 13 с., 1 рис., 1 таблиц, 32 источника, 1 приложение.

Ключевые слова: базы данных, реляционные базы данных, постреляционные базы данных, объектно-реляционная модель хранения данных, эффективность персонала, вовлеченность персонала, компетенции персонала.

Цель работы: разработка базы данных для хранения и обработки оценок трудовой эффективности сотрудников группы компаний.

В данной работе рассматриваются аспекты проектирования и реализации базы данных и приложения для учета трудовой эффективности сотрудников группы команий. В качестве СУБД выбрана PostgreSQL, которая была интегрирована с приложением, реализованным на языке C# с использованем платформы .NET 9.0.

В результате выполненной работы, были созданы база данных и приложение реализующее интерфейс доступа к ней.

1 Анализ предметной области

1.1 Основные понятия корпусной лингвистики

Корпусная лингвистика — раздел компьютерной лингвистики, занимающийся разработкой общих принципов построения и использования лингвистических корпусов (корпусов текстов) с применением компьютерных технологий. Под лингвистическим, или языковым, корпусом текстов понимается большой, представленный в машиночитаемом виде, унифицированный, структурированный, размеченный, филологически компетентный массив языковых данных, предназначенный для решения конкретных лингвистических задач [1]. Существуют также альтернативные определения понятия «языковой корпус». Например, корпус текстов – вид корпуса данных, единицами которого являются тексты или их достаточно значительные фрагменты, включающие, например, какие-то полные фрагменты макроструктуры текстов определённой проблемной области [2].

В современной компьютерной лингвистике понятие «корпус текстов» подразумевает также специализированную поисковую систему, включающую программные средства для поиска данных в корпусе, получения статистической информации и предоставления пользователю результатов в удобной форме, называемую корпусным менеджером [1].

В соответствии с описанным выше, современный корпус предполагает также наличие аннотации или разметки. Аннотация — это приписанная всем единицам выбранного уровня (текст, предложение, словоформа и т. д.) соответствующая лингвистическая информация. При этом аннотирование может быть представлено одновременно для различных уровней [3].

Поиск по слову в корпусе позволяет построить конкорданс — список всех словоупотреблений данного слова в контексте с указанием источников [1]. Таким образом корпусы могут быть использованы для получения разнообразных справок и статистических данных о языковых я речевых единицах. В более широком смысле конкорданс — особый тип словаря, в котором каждое слово или понятие сопровождается минимальным контекстом и всеми случаями употребления в некотором тексте. Иногда конкроданс также определяют как словарь сочетаемости языковых единиц, словарь контекстов [4]. Конкордансы могут быть использованы в лингвистике в следующих целях [5]:

— сравнение различных использований одного слова;
— анализ частотности слов и словосочетаний;
— поиск и исследование фраз и идиом;
— поиск перевода, например, терминологии;
— анализ ключевых слов.

Конкордансы также могут использоваться для анализа творчества отдельных писателей [6, 7] и обучения иностранным языкам [8].

Таким образом объектом корпусной лингвистики является корпус текстов, который, с

одной стороны, представляет собой исходный материал для корпусной лингвистики и других разделов лингвистики; с другой стороны, является результатом деятельности корпусной лингвистики [1].

Предметом корпусной лингвистики являются теоретические основы и практические механизмы создания и использования представительных массивов языковых данных, предназначенных для лингвистических исследований в интересах широкого круга пользователей [1].

1.2 История развития корпусной лингвистики

Истоки корпусной лингвистики, ее приемов и методов прослеживаются начиная с момента создания грамматики санскрита Панини около V в. до н. э., представлявшей собой систематизацию уже существовавшей в ритуальных текстах грамматики [3, 9].

В дальнейшем основным направлением развития корпусной лингвистики стало составление конкордансов основанных на Библии. Первым из известных на данный момент конкордансов является связанный с именем Антония Падуанского «Concordantiae morales sacrae scripturae» («Нравственная конкорданция Священного Писания»), появившийся в начале XIII века [3, 10].

Следующим этапом развития корпусной лингвистики связан с развитием лексикографии и создания словарей языков в XVIII–XIX веках. Появившиеся в это время словари и грамматики составлялись на основе крупных картотек или произведений признанных авторов [3]. Так, например, Словарь живого великорусского языка В. И. Даля основан на материалах как предшествующих ему словарей, так и на самостоятельно подобранных, при этом слова приводятся с примерами использования, что близко по смыслу к конкордансу, построенному на основе существовавших на тот момент литературного и народного языков [3, 11]. В английском языке словарями, основанными на обработке и выборке примеров употребления из существующих произведений литературы, принято считать «Американский словарь английского языка» («An American dictionary of the English language») Н. Вебстера [12] и толковый словарь английского языка («Dictionary of the English language») С. Джонсона [13]. Г. Пауль для составления немецкой грамматики («Deutsche Grammatik» [14]) использовал произведения немецких «классиков» для иллюстрации своих утверждений [1].

В конце XIX – начале XX века начинают появляться корпусы специально созданные для лингвистических исследований или решения практических задач. Одной из таких задач являлся подсчет частотности языковых единиц. Первым словарем такого рода стал «Частотный словарь немецкого языка» («Häufigkeitswörterbuch der deutschen Sprache» [15]). Данный словарь был подготовлен на основе корпуса содержащего одиннадцать миллионов словоупотреблений [3].

В 1909 году был опубликован первый том «A Modern English Grammar on Historical Principles. Part I. Sounds and spellings» [16] датского ученого Отто Есперсена. Основной идеей труда Есперсена был переход от нормативных грамматик к дескриптивным, т. е. анализирующим и описывающим использование языка в живой речи. Для подкрепления изложенных в грамма-

тике тезисов Есперсен специально подбирал источники примеров, общее изложение которых заняло 40 страниц и представляет собой прообраз современного репрезентативного корпуса [3]. В связи с необходимостью ручного подбора и обработки выход всех семи томов данной работы затянулся на 40 лет.

1.3 Классификация корпусов

В зависимости от цели разработки корпусы могут классифицироваться самым разным образом. Выделенные в [1] типы классификаций представлены в таблице 1.1.

Таблица 1.1 — Виды классификаций корпусов

Признак классификации	Типы корпусов
Тип языковых данных	Письменные
	Устные
	Смешанные
«Параллельность»	Одноязычные
	Двуязычные
	Многоязычные
«Литературность»	Литературные
	Диалектные
	Разговорные
	Терминологические
	Смешанные
Цель	Многоцелевые
	Специализированные
Жанр	Литературные
	Фольклорные
	Драматургические
	Публицистические
Доступность	Свободно доступные
	Коммерческие
	Закрытые
Назначение	Исследовательские
	Иллюстративные
Динамичность	Динамические (мониторные)
	Статические
Разметка	Размеченные
	Неразмеченные
Объем текстов	Полнотекстовые
	«Фрагментнотекстовые»

По типу языковых данных корпусы делятся на письменные, устные, смешанные. В письменных корпусах (Брауновский корпус [**?**], корпус Ланкастер-Осло-Берген [**?**]) устная речь не представлена, в устных представлена только устная, к смешанным обычно относят национальные корпусы, представляющие язык в определенный период времени (Национальный корпус

русского языка [**?**], Британский национальный корпус [**?**]) [1].

По критерию параллельности корпусы делятся на одноязычные, двуязычные и многоязычные. В одноязычных противопоставляются диалекты, варианты языка. Двуязычные и многоязычные корпусы объединяют тексты одной и той же тематической области, независимо написанные на двух или нескольких языках. Зачастую основой таких корпусов также является множество текстов-оригиналов на каком-либо исходном языке и текстов-переводов исходных текстов на один или несколько других языков [1]. В [3] двуязычные относят к многоязычным, среди которых дополнительно выделяют выровненные (параллельные), т. е. связанные на уровне абзацев или предложений, и невыровненные. В случае использования параллельных корпусов построенных на основе текстов-переводов возможно автоматическое выравнивание на этапе построения таких текстов [17, 18].

По критерию «литературности» выделяются литературные, диалектные, разговорные и терминологические корпусы [1].

По цели создания корпусы делятся на многоцелевые и специализированные. Многоцелевые корпусы содержат тексты различных жанров (к ним же относятся национальные корпусы), тогда как специализированные корпусы могут ограничиваться одним жанром или группой жанров [1].

Корпусы текстов могут быть классифицированы по жанрам и подразделяться на литературные, фольклорные, драматургические, публицистические и др. Примерами публицистического корпусы могут служить Компьютерный корпус текстов русских газет конца XX-ого века [**?**] и корпус политических метафор [**?**].

По доступности корпусы подразделяются на свободно доступные, коммерческие и закрытые. Стоит отметить, что закрытые корпусы предназначены для специфических задач и потому не представлены в открытом доступе [1]. Иногда дополнительно выделяют также доступные по академической лицензии для использования в научной некоммерческой деятельности [3].

По назначению выделяют исследовательские и иллюстративные корпусы. Исследовательские корпусы создаются с целью с целью изучения различных аспектов функционирования языка. Поскольку этот тип корпусов ориентирован на широкий класс лингвистических задач, что требует при построении таких корпусов использовать специальные способы обеспечения репрезентативности. Такие корпусы содержат как правило от десятков до сотен миллионов словоупотреблений. Иллюстративные корпусы создаются после проведения исследования с целью подтверждения и обоснования полученных результатов [1].

Критерий «динамичность» подразделяет корпусы на динамические и статические. Статические корпусы содержат корпусы небольшого временного промежутка [18]. Типичными представителями такого рода корпусов являются авторские корпусы — коллекции текстов писателей [1]. Динамические корпусы служат для выявления функционирования языковых феноменов на временной шкале — например, изменения значения слов, частоты использования тех или иных синтаксических конструкций [17].

По критерию «разметка» корпусы делятся на размеченные и неразмеченные. В размечен-

ном корпусе словам или предложениям присваиваются метки (тэги) в соответствии с характером разметки: морфологические, синтаксические, семантические, просодические и другие [1].

По критерию «объем текстов» выделяются полнотекстовые и так называемые фрагментотекстовые. Брауновский корпус и корпус Ланкастер-Осло-Берген были строго ограничены числом словоупотреблений, поэтому являются фрагментотекстовыми. К полнотекстовым относятся как правило корпусы определенного автора, а также корпусы коротких текстов, например, корпусы газетных заголовков [1].

В [2] выделяются дополнительно критерии общности и хронологического аспекта. По критерию «общности» корпусы разделяют на коллекции текстов принадлежащие одному писателю и различным. По критерию хронологического аспекта корпусы делят на синхронические и диахронические, которые в сущности совпадают с ранее описанными динамическими и статическими типами.

Дополнительно среди фрагментнотекстовых корпусов выделяют конкордансные и корпусы n-грамм [3].

Таким образом в данной работе рассматриваются письменные, выровненные, многоязычные, научно-технические, свободно доступные, исследовательские, статические, неразмеченные, фрагментнотекстовые корпусы.

1.4 Репрезентативность корпуса

Представительность корпуса получила название репрезентативности, а соотношение отдельных его частей (по разным характеристикам) — сбалансированности [19]. В настоящее время считается, что объем общеязыкового корпуса должен составлять не менее 100 миллионов словоупотреблений. Имеются разные походы к определению репрезентативности. Одним из способов является измерение насыщенности частотного словаря (относительные частоты лексем не меняются или меняются незначительно) [1].

Поскольку корпус представляет собой уменьшенную модель языка для специальных целей (то есть языка технических текстов), под его сбалансированностью понимается необходимое и достаточное пропорциональное представление в корпусе различных текстов данной проблемной области или данного типа, т. е. способность отражать все свойства изучаемого подъязыка [19].

Когда говорят о сбалансированном корпусе, то понимают также сбалансированность его по возможностям: правильно налаженный корпус предполагает модель программно-лингвистического инструмента, поддающуюся настройке и регулированию [19].

1.5 Виды разметок

Джеффри Лич приводит следующие принципы, которым должна подчиняться разметка общедоступного корпуса [20]:

— разметка должна основываться на доступной для пользователя в виде руководства или инструкции схеме анализа, в которой должно быть мотивированно введение каждого параметра;

— разметка общедоступного корпуса должна опираться на общеизвестную систему правил и классификаций;

— должно быть ясно кто и как разрабатывает схему аннотации и каковы ограничения, например юридические или технические, при использовании корпусом [3].

В соответствии с [1, 3, 21, 22] выделяются следующие типы разметки:

— анафорическая;

— дискурсная;

— жанровая;

— издательская;

— метатекстовая;

— морфологическая;

— синтаксическая;

— семантическая;

— служебная;

— структурная;

— терминологическая.

Анафорическая разметка необходима для установления референтных связей, т. е. соотнесение включенных в речь имен, именных выражений или их эквивалентов к реальным объектам. В связи с широким распространением в технических текстах аббревиатур и других референций вместо определенного термина (например, «аппарат», «ЛА» вместо «летательный аппарат»), при использовании средств машинной разметки таких текстов необходимо учесть все возможные референции встречающихся терминов, чтобы итоговая статистическая картина частотности употребления термина не была искаженной.

Дискурсная разметка зачастую реализуется для текстов художественного и разговорного стилей, речевых корпусов. Поскольку научно-техническим текстам не свойственно присутствие дискурсных единиц [23], реализация данной разметки для корпусов таких текстов не является необходимой.

Жанровая разметка для корпуса научно-технических текстов реализуется при отборе текстов для наполнения корпуса.

Издательская разметка отражает особенности форматирования текста, которые могут быть использованы при реализации других видов разметок.

Метатекстовая (экстралингвистическая) подразумевает под собой добавление к тексту внетекстовых характеристик: авторов, год, издательство, журнал, жанр и другие особенности текста или обстоятельства его создания. Выделяют два класса факторов влияющих на язык текстов и описываемых метатекстовой разметкой [1]:

— внешние, внеязыковые факторы (E — external);

— внутренние, относящие к внешним признакам текста (I — internal).

Дж. Синклер выделяет три группы E-факторов [24]:

— E1 (origin) — факторы, относящиеся к созданию текста автором;

— E2 (state) — факторы относящиеся к внешним признакам текста;

— E3 (aims) — факторы, относящиеся к причинам создания текста и его влиянию на аудиторию.

И две группы I-факторов:

— I1 (topic) — предметная область текста;

— I2 (style) — стилистические особенности текста (стиль, жанр).

Морфологическая разметка включает в себя: лемму (начальную форму слова), признак части речи, признаки грамматических категорий в зависимости от части речи. Данный тип разметки — основной и реализован в большинстве корпусов, а также является основой для дальнейших форм анализа — синтаксического и семантического. Кроме того в современных корпусах, этот тип разметки может быть реализован автоматически [1].

В корпусной лингвистике синтаксическая разметка основана на грамматике зависимостей [1, 3]. Тексты, получившие синтаксическую разметку известны в англоязычной литературе как treebanks [25]. Пример визуализации синтаксических зависимостей, отображаемых синтаксической разметкой, представлен на рисунке 1.1.

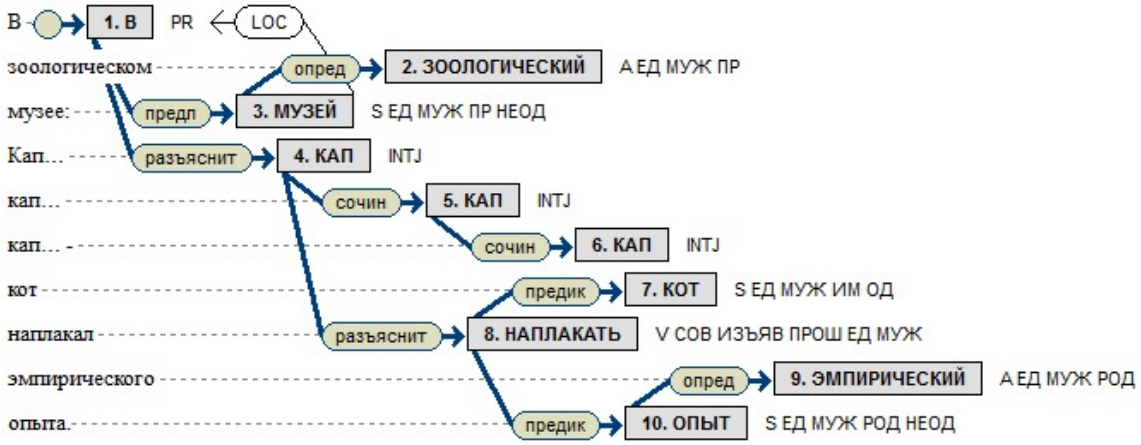

Рисунок 1.1 — Визуализация синтаксических зависимостей в НКРЯ

Семантическая разметка состоит в приписывании единицам текста одной или нескольких семантических категорий. Семантические тэги чаще всего обозначают семантические категории, к которым относится данное слово или словосочетание, и более узкие подкатегории, специфицирующие его значение. Семантическая разметка корпусов предусматривает опреде-

ление значения слов, разрешение омонимии и категоризацию слов, выделение тематических классов и т. д. [1].

При этом к семантической разметке относят и категоризацию семантических ролей [3]. Семантические роли под названием «глубинные падежи» впервые выделены и описаны Ч. Филлмором [26]. Семантическая роль имени при данном предикате является частью семантики этого предиката и отражает общие свойства участников определенных групп ситуаций. В данном определении предполагается, что предикатные (глагольные) лексемы описывают «ситуации», а именные лексемы — «участников» этих ситуаций, которые называются аргументами предикатов. Состав и количество семантических ролей, выделяемых при том или ином описании, зависят от конкретной задачи и могут существенно различаться; в большинстве случаев достаточно сравнительно небольшого набора из двух - трех десятков ролей. [27].

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Захаров В. П., Богданова С. Ю.* Корпусная лингвистика: учебник для студентов гуманитарных вузов. — Иркутск: ИГЛУ, 2011. — 161 с., ISBN 978-5-88267-316-0.

2. *Грудева Е. В.* Корпусная лингвистика: учеб. пособие. — М: ФЛИНТА, 2012. — 165 с., ISBN 978-5-9765-1497-3.

3. *В. Копотев М.* Введение в корпусную лингвистику. — Прага: Animedia Company, 2014. — 231 с., ISBN: 978-80-7499-067-0.

4. *Доминикан А. И.* Конкорданс как инструмент для изучения значения слова // *Вестник Тверского государственного университета. Серия: Филология*. — 2016. — no. 4. — Pp. 85–89.

5. *Добрынина К. С.* О методике работы над конкордансами // *Филологические науки. Вопросы теории и практики*. — 2012. — Vol. 1, no. 12. — Pp. 59–63.

6. *Калинкин В. М., Шульдишова А. А.* Конкорданс как произведение лексикографии и инструмент исследований (на материале лирической трилогии А. Блока) // *Славистика*. — 2023.

7. *Васильев Н.Л., Жаткин Д.Н.* Конкорданс к поэзии А. С. Пушкина, подготовленный в 1930-х гг. Г. А. Шенгели // *Известия РАН. Серия литературы и языка*. — 2019. — Vol. 78, no. 3. — Pp. 39–51.

8. *Нагель О. В.* Корпусная лингвистика и ее использование в компьютеризированном языковом обучении // *Язык и культура*. — 2008. — no. №4. — Pp. 53–59.

9. *Волошина О. А.* Принципы описания языка в древнеиднийской грамматике Панини // *Вестник нижегородского университета им Н. И. Лобачевского*. — 2018. — no. 1. — Pp. 160–165.

10. The Routledge handbook of corpus linguistics / Ed. by Anne O'Keffe, Michael McCarthy. — Routledge, 2010. — 682 c., ISBN 978-0-203-85694-9.

11. *Даль В. И.* Толковый словарь живого великорусского языка. — Москва : Изд. общ-ва любителей Российской словесности, 1863.

12. *Webster Noah*. An American dictionary of the English language / Ed. by Chauncey A. Goodrich. — Springfield, Mass.: G. & C. Merriam, 1865. — 1768 c.

13. *Johnson Samuel*. A dictionary of the English language / Ed. by Walker John. — London: W. Tegg & co, 1850. — 831 c.

14. *Paul German*. Deutsche Grammatik. — M. Niemeyer, 1916. — 378 с.

15. *Kaeding F. W.* Häufigkeitswörterbuch der deutschen Sprache. — E.S. Mittler & Sohn, 1898. — 671 с.

16. *Jespersen Otto*. A Modern English Grammar on Historical Principles. Part I. Sounds and spellings. — London: George Allen & Unwin, 1909. — 485 с.

17. *Баранов А. Н.* Введение в прикладную лингвистику: Учебное пособие. — М.: Эдиториал УРСС, 2001. — 360 с., ISBN 5-8360-0196-0.

18. *Зубов А.В., Зубова И.И.* Информационные технологии в лингвистике: Учеб. пособие. — М.: Издательский центр «Академия», 2004. — 208 с.

19. *Захаров В. П., Азарова И. В., Митрофанова О. А., Попов А. М., Хохлова М. В.* Моделирование в корпусной лингвистике: специализированные корпусы русского языка / Ed. by Захаров В. П. — СПб.: Изд-во С.-Петерб. ун-та, 2019. — 208 с., ISBN 978-5-288-05902-5.

20. *Leech Geoffrey*. Introducing corpus annotation. — 1997.

21. *Лесников С. В.* Виды разметок текстовых корпусов русского языка // *Научно-техническая информация. Серия 2: Информационные процессы и системы*. — 2019.

22. Национальный корпус русского языка: исследования и разработки. — М., 2019. — Vol. 21 of *Труды Института русского языка им. В.В. Виноградова*.

23. *Богданова-Бегларян Н. В.* Дискурсивная единица типа (того что): функционирование в устной спонтанной речи и возможности лексикографического описания // *Проблемы истории, филологии, культуры*. — 2014. — no. 3 (45). — Pp. 252–254.

24. *Sinclair John M.* Preliminary recommendations on text typology. — 1996. `http://www.ilc.pi.cnr.it/EAGLES96/texttyp/texttyp.html`.

25. Treebanks: Building and Using Parsed Corpora / Ed. by Anne Abeillé. — Dordrecht: Springer, 2003. — Vol. 20 of *Text, Speech and Language Technology*.

26. *Fillmore Charles J.* The case for case // Universals in Linguistic Theory / Ed. by Emmon Bach, Robert T. Harms. — New York, NY: Holt, Rinehart and Winston, 1968. — Pp. 1–88.

27. *Плунгян В. А.* Общая морфология: Введение в проблематику. — 2-е, исправленное изд. — М.: Едиториал УРСС, 2003.