Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н. Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

Система управления корпусными данными параллельных корпусов технических текстов

Группа: ИУ7-74Б
Студент: Бугаков Иван Сергеевич
Научный руководитель: Строганов Юрий Владимирович

2026 г.

Цель и задачи работы

Цель работы — сравнительный анализ существующих методов построения разметок текстов и систем управления корпусными данными.

Задачи:

- проанализировать предметную область использования параллельных корпусов в корпусной лингвистике, ввести основные понятия, привести классификацию корпусов текстов;
- перечислить методы или группы методов построения разметки текстов;
- сформулировать критерии и сравнить перечисленные методы построения разметки;
- сформулировать критерии и сравнить существующие системы управления корпусными данными.

Сравнение методов построения анафорической разметки

Метод	Требуются морфологические характеристики	Требуются синтаксические характеристики	Разрешение местоименной анафоры	Разрешение кореферентной анафоры	Применимость к различным языкам	Точность
Вычисление семантической близости	Нет	Нет	Нет	Да	Да, при наличии онтологии языка	59%
CogNIAC	Да	Нет	Да	Нет	Нет	Нет данных
Метод опорных векторов	Да	Да	Да	Нет	Да	62%
Деревья принятия решений (ID3)	Да	Да	Да	Нет	Да	52.04%
Деревья принятия решений (Extra Trees)	Да	Да	Да	Нет	Да	66.05%

Сравнение методов построения морфологической разметки

Метод	Использование грамматического словаря	Требуется контекст	Обработка не словарных словоформ	Скорость обработки (тыс. слов/с)	Применимость к различным языкам	Accuracy	PPMV
Finite State Transducer	Да	Нет	Нет	Нет данных	Нет	97%	Нет данных
Mystem	Да	Нет	Да	65	Да	Нет данных	778/41
Stemka	Нет	Нет	Да	380	Да	Нет данных	787/493
Pymorphy2	Да	Нет	Да	2	Да	Нет данных	Нет данных
Метод опорных векторов	Нет	Да	Да	Нет данных	Да	92.47%	Нет данных
Meta-BiLSTM	Нет	Да	Да	Нет данных	Да	93.31%	Нет данных

Сравнение методов построения синтаксической разметки

Метод	Использование морфологических характеристик	Требуется проективность языка	Применимость к различным языкам	Вычислительная сложность	Точность
Алгоритм CKY	Нет	Да	Да, при наличии грамматики	$O(n^3)$	Нет данных
Алгоритм shift-reduce	Да	Да	Да, при наличии грамматики	$O(n)$	89%
MaltParser	Да	Нет	Да	$O(n)$	Нет данных
LaPaRus	Да	Да	Нет	Нет данных	81.66%

Сравнение существующих корпус менеджеров

Название корпуса	Степень автоматизации построения морфологической разметки	Степень автоматизации построения синтаксической разметки	Степень автоматизации выполнения выравнивания
Параллельный корпус НКРЯ	3	2 (UD) / 0 (СинТагРус)	2
Параллельный корпус казахского и русского языков (Национальный корпус казахского языка)	3	Не реализована	0
Татарско-русский параллельный корпус «Туган тел»	3	2	2
Китайско-русский параллельный дискурсивный корпус	Нет данных	2	0
Параллельный корпус русского языка и диалекта русских цыган	2	Не реализована	1
Parallel GUM RST Corpus	2	2	2
Параллельный корпус списков славянского паримейника	1	1	1

Выводы

Исходя из результатов сравнения методов разрешения анафоры были сделаны следующие выводы:

- большинство рассмотренных методов разрешения анафоры требуют морфологических и синтаксических характеристик;
- большинство рассмотренных методов сосредоточены на разрешении местоименной анафоры;
- среди рассмотренных нет единого метода для разрешения местоименной и кореферентной анафоры;
- методы, основанные на машинном обучении, могут быть применимы к различным языкам при наличии размеченных данных для обучения;
- в разрешении местоименной анафоры методы основанные на машинном обучении показывают большую точность, около 65%.

Исходя из результатов сравнения методов морфологического анализа были сделаны следующие выводы:

- методам, не основанным на машинном обучении, требуется грамматических словарь для определения морфологических характеристик;
- методам, не основанным на машинном обучении не требуется контекст слоформы для определения морфологических характеристик, однако в случае омонимии, такие методы не дают однозначного разбора;
- методы основанные на конечных автоматах (FST) не могут быть применены к различным языкам;
- большинство рассмотренных методов способны обрабатывать не словарные словоформы;
- алгоритмы стемминга показывают значения скорости обработки в десятки тысяч словоформ в секунду;
- точность (accuracy) рассмотренных методов превышает 90%;
- подход с использованием Meta-BiLSTM показывает наибольшую точность (accuracy) в получении морфологических характеристик среди методов допускающих использование в различных языках.

Выводы

Исходя из результатов сравнения методов синтаксического анализа были сделаны следующие выводы:

- большинство рассмотренных методов построения деревьев зависимостей имеют линейную вычислительную сложность;
- большинству рассмотренных методов построения синтаксической разметки требуются морфологические характеристики словоформ;
- фундаментальным ограничением большинства рассмотренных методов является требование проективности языка;
- большинство рассмотренных методов могут быть применены к различным языкам.

Исходя из результатов сравнения существующих систем управления корпусными данными сделаны следующие выводы:

- наибольшую степень автоматизации выполнения разметок и выравнивания предоставляют системы управления параллельным корпусом НКРЯ и татарско-русским корпусом «Туган тел»;
- ни одна из систем управления корпусными данными не обеспечивает полностью автоматизированного выполнения разметок и выравнивания.