


Скетчи, коллокации, коллигации, частотные и ключевые слова: основы корпусной математики для переводчиков



Ирина Евгеньевна Пинхасик, РГГУ / МГЛУ

Зимняя школа перевода СПР, 29–31 января 2025 г.



Это я

Ирина Евгеньевна Пинхасик

ст. преп. учебно-научного центра
компьютерной лингвистики
Института лингвистики РГГУ

ст. преп. кафедры скандинавских,
нидерландского и финского языков
Переводческого факультета МГЛУ

переводчик с чешского и
болгарского

fablecraft@gmail.com,
vk, tg @butanojoou

Материалы лекции



Устойчивые сочетания слов

- теория фразеологии:
различные типы сочетаний
в зависимости от их устойчивости
- критерии:
 - уникальность
 - некомпозициональность значения
 - частотность
 - связанность
 - структура
- возможные задачи:
 - терминология
 - лексические функции
 - машинный перевод
 - именованные сущности
 - и т.д.



Устойчивые сочетания слов

- проблемы:
 - нечеткий семантический критерий
 - нужны данные о частотности
- решение: обращение к корпусной лингвистике
- лексико-грамматические шаблоны + статистика



N-граммная модель

- n-грамма – последовательность из n элементов (звуков, слогов, слов или букв)



Шкала п-грамм корпуса

- случайные сочетания
(и в, красный не)
- свободные сочетания
(вы были, эта книга)
- коллокации
(ставить условие, резкий рост)
- неоднословные номинации и термины
(Иван Грозный, лекарственное средство)
- фраземы (идиомы)
(ничего себе, всего доброго)



Униграммная модель

- каждое слово имеет некоторую частотность, заранее определенную по текстам
- появление каждого следующего слова считается независимым событием
- мешок слов (bag of words) – упрощенное представление текста, в котором он выглядит как набор составляющих его слов без какого-либо учета грамматики и порядка слов, но с сохранением информации об их количестве
- *бить* 49 969 примеров,
баклуши 241 пример,
бить баклуши 102 примера

389 470 868 слов в корпусе

The Bag of Words Representation

I love this movie! It's sweet, but with satirical humor. The dialogue is great and the adventure scenes are fun... It manages to be whimsical and romantic while laughing at the conventions of the fairy tale genre. I would recommend it to just about anyone. I've seen it several times, and I'm always happy to see it again whenever I have a friend who hasn't seen it yet!

15




it	6
I	5
the	4
to	3
and	3
seen	2
yet	1
would	1
whimsical	1
times	1
sweet	1
satirical	1
adventure	1
genre	1
fairy	1
humor	1
have	1
great	1
...	...

Коллокации

- коллокация (collocation) – сочетание слов, которое встречается чаще, чем это предсказывает модель мешка слов
- узел коллокации / ключ (node) – искомое слово
- коллокаты (collocates) – слова, встречающиеся слева или справа от узла / ключа и образующие с ним коллокации
- некоторые характеристики коллокаций



Графы коллокаций



Коллокации

КЛЮЧ

КОЛЛОКАТ

My **love** is like a red, red rose that's newly sprung in June: My **love** is like the melody that's sweetly played in tune. As fair art thou, my bonnie lass, so deep in **love** am I: And I **will love** thee still, my dear, till a' the seas gang dry. Till a' the seas gang dry, my dear, and the rocks melt wi' the sun : And I **will love** thee still, my dear, while the sands o' life shall run. And fare thee weel, my **only love**, and fare thee weel a while! And I will come again, my **love**, thou' it were ten thousand mile.

контекстное окно (размах): 1L 1R

(Robert Burns, "A Red, Red Rose")

Модель «мешка слов»

fare art And like red, sweetly in **love love**, And gang wi' played like dear, life shall rocks
sprung the Till deep **my my** And still, weel, again, ten the the while! is till And As I: a' only
come were sands sun: dry, and gang it a' the still, **My** thee will in **my** bonnie My red is a
run. **my love** thee thou, melt the seas and th'ou' I the I lass, I melody thee a **my** am rose
love dear, that's **love** newly **love** fare **love**, will o' so dry. fair thee will that's in while June:
my seas tune. mile. thousand weel dear,

$$\text{expected frequency of collocation} = \frac{\text{node frequency} \times \text{collocate frequency}}{\text{no. of tokens in text or corpus}}$$

Коллокации в лингвистике

- в широком смысле – комбинация двух или более слов, имеющих тенденцию к совместной встречаемости
- традиционные подходы к описанию понятия коллокации:
 - статистический подход [Firth 1957; Firth 1968 и др.]
 - семантико-синтаксический подход [Телия 1996; Cowie 1978; Hausmann 1979; Hausmann 1985 и др.]

Статистический подход

- коллокация – это привычное, традиционное сочетание слов в речи, звучащее правильно, естественно для носителей языка
- характерные, часто встречающиеся сочетания слов, «появление которых рядом друг с другом основывается на регулярном характере взаимного ожидания и задается не грамматическими, а чисто семантическими факторами» [Firth 1957]
- показатель – частота совместной встречаемости

Семантико-синтаксический подход


- коллокация – словосочетание, в котором одно из слов является семантической доминантой, а второе выбирается в зависимости от него для передачи смысла всего выражения
- отношение между отдельными лексическими элементами в пределах синтаксической единицы (The Concise Oxford Dictionary of Linguistics)
- одно из ключевых свойств коллокаций – невозможность предсказания таких сочетаний на основе значений входящих в них компонентов

Типы коллокаций

- связанные слова не обязаны находиться в непосредственном соседстве
- поверхностные коллокации с заранее определенным размахом (span)
 - (L1,R0) – непосредственное соседство слева
 - (L4,R4) – совместная встречаемость в пределах ± 4 слов
- текстуальные коллокации (в одном тексте)
- синтаксические коллокации (в одной синтаксической структуре)

Ранжирование коллокаций

- если пользоваться только униграммной моделью, некоторые словосочетания будут иметь частотность выше ожидаемой, а очень многие – ниже
- нужно ранжирование коллокаций в зависимости от того, насколько сильно реальная наблюдаемая (observed) частотность превышает ожидаемую (expected) частотность
- как оценить в униграммной модели вероятность, что слово w_2 встретится в интервале (L_m, R_n) от слова w_1 ?



Меры ассоциации коллокаций (association measures)

- специальные метрики, которые основываются на предположении, что совместная встречаемость единиц в составе коллокации должна быть выше, чем у каждой из них по отдельности
- показатели силы синтагматической связи между элементами словосочетаний
- исходные данные: частота совместной встречаемости, наблюдаемая и ожидаемая частоты слов или словоформ (ключевого слова и коллоката)
- корпуса как источники достоверных данных о частотах

Меры ассоциации коллокаций

- взаимная информация $MI(n,c) = \log_2 \frac{f(n,c) \times N}{f(n) \times f(c)}$
- t-score $t\text{-score} = \frac{f(n,c) - \frac{f(n) \times f(c)}{N}}{\sqrt{f(n,c)}}$
- логарифмическое правдоподобие $\log\text{-likelihood} = 2 \sum_{ij} O_{ij} \times \log \frac{O_{ij}}{E_{ij}}$
- logDice $\log Dice = 14 + \log_2 \frac{2f(n,c)}{f(n) + f(c)}$

MI (mutual information)

- MI – mutual information; n – ключевое слово; c – коллокат;
- $f(n,c)$ – частота встречаемости ключевого слова n в паре с коллокатом c ;
- $f(n)$, $f(c)$ – абсолютные (независимые) частоты ключевого слова n и слова c в корпусе (тексте);
- N – общее число словоформ в корпусе (тексте)
- лучше ищет довольно редкие коллокации узкой тематической области (термины, составные названия компаний или сочетания имени и фамилии)

$$MI = \log_2 \frac{f(n,c) \times N}{f(n) \times f(c)}$$

MI (mutual information)

NoSketch Engine

школа

Araneum Russicum III Minus (Russian, 19.03) 125 M

guest

Home

Search

Word list

Corpus info

My jobs

User guide

Save

concordance

Frequency

Node tags

Node forms

Doc IDs

Collocation candidates

Page 1 Go Next >

	Cooccurrence count	Candidate count	T-score	MI	log likelihood	logDice
P N Спиркиной	13	12	3.604	11.625	214.488	3.312
P N демунципализации	5	5	2.235	11.510	79.782	1.934
P N общественно-активных	6	6	2.448	11.510	95.739	2.197
P N малокомплектной	5	5	2.235	11.510	79.782	1.934
P N Чародейства	8	8	2.827	11.510	127.653	2.612
P N Хороль	6	6	2.448	11.510	95.739	2.197
P N Голубоченской	6	6	2.448	11.510	95.739	2.197
P N RHODEC	6	6	2.448	11.510	95.739	2.197
P N джур	9	9	2.998	11.510	143.610	2.782
P N Большеокуловской	5	5	2.235	11.510	79.782	1.934
P N OnSight	5	5	2.235	11.510	79.782	1.934
P N Токицукадзэ	5	5	2.235	11.510	79.782	1.934
P N сад-базовая	5	5	2.235	11.510	79.782	1.934
P N Воскресную	5	5	2.235	11.510	79.782	1.934
P N очаково-матвеевское	5	5	2.235	11.510	79.782	1.934
P N Общественно-активная	5	5	2.235	11.510	79.782	1.934
P N НеоМы	6	6	2.448	11.510	95.739	2.197
P N воскресной	63	64	7.934	11.487	995.049	5.587
P N церковно-приходской	28	31	5.289	11.363	427.089	4.419
P N физико-математическую	9	10	2.998	11.358	137.109	2.782
P N общественно-активной	9	10	2.998	11.358	137.109	2.782
P N Выш	41	46	6.400	11.344	622.630	4.968
P N церковно-приходская	14	16	3.740	11.317	211.339	3.419
P N ICBT	7	8	2.644	11.317	105.668	2.419
P N No315	7	8	2.644	11.317	105.668	2.419
P N Детско-юношеская	14	16	3.740	11.317	211.339	3.419

t-score

- n – ключевое слово; c – коллокат;
- $f(n,c)$ – частота встречаемости ключевого слова n в паре с коллокатом c ;
- $f(n)$, $f(c)$ – абсолютные (независимые) частоты ключевого слова n и слова c в корпусе (тексте);
- N – общее число словоформ в корпусе (тексте)
- лучше справляется с высокочастотными общеязыковыми конструкциями (сложные предлоги, вводные конструкции и т.п.)

$$t - score = \frac{f(n,c) - \frac{f(n) \times f(c)}{N}}{\sqrt{f(n,c)}}$$

t-score

NoSketch Engine

школа

▼

Q

Araneum Russicum III Minus (Russian, 19.03) 125 M

...

guest

...

Home

Search

Word list

Corpus info

My jobs

User guide ↗

Save

🔍 concordance

Frequency

Node tags

Node forms

Doc IDs

?

Collocation candidates

Page

1

Go

Next >

	Cooccurrence count	Candidate count	T-score	MI	log likelihood	logDice
P N в	20,128	3,474,424	133.477	4.078	86,367.756	7.550
P N .	19,511	5,982,152	124.998	3.249	61,884.930	6.729
P N ,	21,304	9,065,926	124.663	2.776	55,670.273	6.260
P N и	11,425	3,574,495	95.422	3.220	33,375.130	6.693
P N "	6,070	1,979,417	69.199	3.161	16,551.972	6.619
P N на	4,256	1,690,616	56.353	2.876	9,955.281	6.330
P N с	3,205	1,136,415	49.730	3.040	8,075.089	6.476
P N быть	3,065	979,501	49.296	3.190	8,283.269	6.618
P N --	2,673	817,620	46.279	3.253	7,414.200	6.669
P N по	2,584	724,367	45.947	3.379	7,571.612	6.786
P N год	2,344	390,229	45.651	4.130	9,131.977	7.470
P N (	2,520	705,677	45.380	3.380	7,385.721	6.785
P N средний	2,069	28,738	45.269	7.714	18,259.808	9.887
P N для	2,485	679,737	45.174	3.414	7,387.753	6.816
P N детский	1,877	32,932	43.063	7.377	15,654.809	9.664
P N не	2,553	1,275,951	41.869	2.545	4,887.049	5.987
P N школа	1,760	42,855	41.602	6.904	13,499.355	9.394
P N)	2,217	789,707	41.334	3.033	5,526.170	6.447
P N из	1,932	446,717	40.470	3.657	6,319.312	7.014
P N :	2,026	649,076	40.067	3.186	5,425.357	6.584
P N -	1,978	610,737	39.766	3.239	5,426.133	6.631
P N класс	1,398	28,528	37.128	7.159	11,212.605	9.325
P N к	1,607	488,752	35.907	3.261	4,440.541	6.630
P N дитя	1,303	69,907	35.433	5.764	7,916.984	8.564
P N высший	1,262	16,866	35.361	7.769	11,214.130	9.435
P N я	1,577	526,102	35.169	3.128	4,095.398	6.505

log-likelihood

- n – ключевое слово; c – коллокат;
- $f(n,c)$ – частота встречаемости ключевого слова n в паре с коллокатом c ;
- $f(n)$, $f(c)$ – абсолютные (независимые) частоты ключевого слова n и слова c в корпусе (тексте);
- N – общее число словоформ в корпусе (тексте)

$$\text{log-likelihood} = 2 \sum f(n,c) \times \log_2 \frac{f(n,c) \times N}{f(n) \times f(c)}$$

log-likelihood

NoSketch Engine

школа

Araneum Russicum III Minus (Russian, 19.03) 125 M

guest

Home

Search

Word list

Corpus info

My jobs

User guide

Save

concordance

Frequency

Node tags

Node forms

Doc IDs

Collocation candidates

Page 1 Go Next >

	Cooccurrence count	Candidate count	T-score	MI	log likelihood	logDice
P N в	20,128	3,474,424	133.477	4.078	86,367.756	7.550
P N .	19,511	5,982,152	124.998	3.249	61,884.930	6.729
P N ,	21,304	9,065,926	124.663	2.776	55,670.273	6.260
P N и	11,425	3,574,495	95.422	3.220	33,375.130	6.693
P N средний	2,069	28,738	45.269	7.714	18,259.808	9.887
P N "	6,070	1,979,417	69.199	3.161	16,551.972	6.619
P N детский	1,877	32,932	43.063	7.377	15,654.809	9.664
P N школа	1,760	42,855	41.602	6.904	13,499.355	9.394
P N общеобразовательный	1,018	2,075	31.883	10.482	13,392.940	9.536
P N учащийся	1,233	9,278	35.023	8.598	12,444.274	9.598
P N начальный	1,080	6,680	32.793	8.881	11,353.183	9.480
P N высший	1,262	16,866	35.361	7.769	11,214.130	9.435
P N класс	1,398	28,528	37.128	7.159	11,212.605	9.325
P N на	4,256	1,690,616	56.353	2.876	9,955.281	6.330
P N учиться	1,057	11,560	32.389	8.059	9,828.102	9.314
P N сад	1,074	14,069	32.624	7.798	9,583.325	9.272
P N учитель	1,037	13,478	32.058	7.810	9,269.153	9.236
P N год	2,344	390,229	45.651	4.130	9,131.977	7.470
P N No	1,135	24,222	33.443	7.094	8,992.742	9.114
P N ученик	916	9,738	30.155	8.099	8,568.330	9.156
P N быть	3,065	979,501	49.296	3.190	8,283.269	6.618
P N с	3,205	1,136,415	49.730	3.040	8,075.089	6.476
P N дитя	1,303	69,907	35.433	5.764	7,916.984	8.564
P N обучение	1,016	25,699	31.598	6.849	7,696.750	8.923
P N по	2,584	724,367	45.947	3.379	7,571.612	6.786
P N --	2 673	817 620	46 279	3 253	7 414 200	6 669

25

logDice

- n – ключевое слово; c – коллокат;
- $f(n, c)$ – частота встречаемости ключевого слова n в паре с коллокатом c ;
- $f(n)$, $f(c)$ – абсолютные (независимые) частоты ключевого слова n и слова c в корпусе (тексте);
- N – общее число словоформ в корпусе (тексте)

$$\log Dice = 14 + \log_2 \frac{2f(n, c)}{f(n) + f(c)}$$

logDice

NoSketch Engine

школа

Araneum Russicum III Minus (Russian, 19.03) 125 M

guest

Home

Search

Word list

Corpus info

My jobs

User guide

Save

concordance

Frequency

Node tags

Node forms

Doc IDs

Collocation candidates


Page 1 Go Next >

	Cooccurrence count	Candidate count	T-score	MI	log likelihood	logDice
P N средний	2,069	28,738	45.269	7.714	18,259.808	9.887
P N детский	1,877	32,932	43.063	7.377	15,654.809	9.664
P N учащийся	1,233	9,278	35.023	8.598	12,444.274	9.598
P N общеобразовательный	1,018	2,075	31.883	10.482	13,392.940	9.536
P N начальный	1,080	6,680	32.793	8.881	11,353.183	9.480
P N высший	1,262	16,866	35.361	7.769	11,214.130	9.435
P N школа	1,760	42,855	41.602	6.904	13,499.355	9.394
P N класс	1,398	28,528	37.128	7.159	11,212.605	9.325
P N учиться	1,057	11,560	32.389	8.059	9,828.102	9.314
P N сад	1,074	14,069	32.624	7.798	9,583.325	9.272
P N учитель	1,037	13,478	32.058	7.810	9,269.153	9.236
P N ученик	916	9,738	30.155	8.099	8,568.330	9.156
P N No	1,135	24,222	33.443	7.094	8,992.742	9.114
P N обучение	1,016	25,699	31.598	6.849	7,696.750	8.923
P N директор	872	22,744	29.265	6.805	6,548.820	8.766
P N музыкальный	680	9,556	25.951	7.697	5,962.566	8.731
P N выпускник	564	4,473	23.684	8.522	5,620.041	8.609
P N дитя	1,303	69,907	35.433	5.764	7,916.984	8.564
P N окончить	526	3,832	22.877	8.645	5,336.474	8.528
P N искусство	669	17,655	25.631	6.788	5,005.261	8.500
P N учебный	609	16,720	24.445	6.731	4,506.858	8.387
P N образование	853	42,045	28.712	5.886	5,317.538	8.362
P N спортивный	549	14,456	23.219	6.791	4,108.399	8.294
P N учреждение	591	21,762	24.003	6.307	4,024.564	8.227
P N образовательный	493	12,214	22.015	6.879	3,749.461	8.196
P N преподаватель	456	8,683	21,214	7,259	3,711,655	8,179

Меры ассоциации коллокаций

ID	Statistic	Equation	ID	Statistic	Equation
1	Freq. of co-occurrence	O_{11}	8	T-score	$\frac{O_{11} - E_{11}}{\sqrt{O_{11}}}$
2	MU	$\frac{O_{11}}{E_{11}}$	9	DICE	$\frac{2 \times O_{11}}{R_1 + C_1}$
3	MI (Mutual information)	$\log_2 \frac{O_{11}}{E_{11}}$	10	LOG DICE	$14 + \log_2 \frac{2 \times O_{11}}{R_1 + C_1}$
4	MI2	$\log_2 \frac{O_{11}^2}{E_{11}}$	11	LOG RATIO	$\log_2 \frac{O_{11} \times R_2}{O_{21} \times R_1}$
5	MI3	$\log_2 \frac{O_{11}^3}{E_{11}}$	12	MS (Minimum sensitivity)	$\min\left(\frac{O_{11}}{C_1}, \frac{O_{11}}{R_1}\right)$
6	LL (Log likelihood)	$2 \times \left(O_{11} \times \log \frac{O_{11}}{E_{11}} + O_{21} \times \log \frac{O_{21}}{E_{21}} + O_{12} \times \log \frac{O_{12}}{E_{12}} + O_{22} \times \log \frac{O_{22}}{E_{22}} \right)$	13	DELTA P	$\frac{O_{11}}{R_1} - \frac{O_{21}}{R_2}; \frac{O_{11}}{C_1} - \frac{O_{12}}{C_2}$
7	Z-score	$\frac{O_{11} - E_{11}}{\sqrt{E_{11}}}$	14	Cohen's d	$\frac{Mean_{in\ window} - Mean_{outside\ window}}{pooled\ SD}$

Меры ассоциации коллокаций



Сравнение мер ассоциации

- чем больше полученная мера ассоциации, тем более устойчивы найденные сочетания
- плохо приспособлены для измерения сочетаний бóльших, чем двухсловные

Тест MI	T-score
Бритни Спирс	по словам
Эльвира Набиуллина	а также
Ле Бурже	со ссылкой
Лионель Месси	ссылкой на
мысе Канаверал	по данным
бин Ладена	кроме того
Норильского никеля	РИА Новости
дельты Нигера	этом сообщает
Ак Барс	при этом
тротиловом эквиваленте	в том
тройскую унцию	в России
Ролан Гаррос	во время
дель Торо	пока не
дель Потро	о том
Арбат Престиж	в результате
РАО ЕЭС	настоящее время
Салават Юлаев	миллионов долларов
Арсений Яценюк	связи с
голубых фишек	сообщает РИА
адронного Коллайдера	в результате

[Ягунова, Пивоварова 2010]

Параметры коллокаций (collocation parameters notation) [Brezina et al. 2015]

Statistic ID	Statistic name	Statistic cut-off value	L and R span	Minimum collocate freq. (C)	Minimum collocation freq. (NC)	Filter
4b	MI2	3	L5-R5	5	1	function words removed
4b-MI2(3), L5-R5, C5-NC1; function words removed						

Example

Коллигации

- коллигации – это коллокации с учетом грамматических отношений между их элементами
- Colligation is a type of collocation, but where a lexical item is linked to a grammatical one. *Surprising, amazing* and *astonishing* are nearly synonymous. We can say *it is astonishing /surprising /amazing*, but we tend to say *it is not surprising* and not the others – *surprising* colligates with the negative

Коллигации

- задача: найти не просто слова, которые значимо часто сочетаются со словом w, а, например, прямые дополнения или определения к этому слову
- подходы к решению:
 - отобрать среди всех коллокаций только прямые дополнения
 - искать коллокации только среди прямых дополнений
- проблема: отсутствие синтаксической разметки
- подход к решению:
 - подменить синтаксическую разметку морфологической

Скетчи и скетч-грамматики

- скетч слова – описание сочетаемости слова с распределением коллокаций по типам грамматической связи
- скетч-грамматика – формализованное описание типов грамматической связи через морфологические категории
- как оценить точность определения того или иного типа связи в скетч-грамматике?
 - запрос, соответствующий определению в скетч-грамматике
- как оценить полноту определения того или иного типа связи в скетч-грамматике?
 - поиск необходимых структур в золотом стандарте и проверка их соответствия скетч-грамматике

Поиск коллокаций в НКРЯ

Поиск точных форм ? ▾

Поиск коллокаций ? ^

По умолчанию поиск ведется по предпочтительным разборам, совпадения соседних слов исключаются.

Ключ

Лемма

🔍 ?

добавить свойство



Коллокат

Лемма

🔍 ? ✕

Грамм. признаки

выбрать ? ✕

Расстояние

от:

до:

-3

3

добавить свойство



Искать

Сбросить

Лексико-грамматический поиск ? ▾

Поиск коллокаций в НКРЯ

Запрос

Вернуться к поиску

• 7085 текстов • 794 коллокации

предпочтительные разборы, совп...

студент

А, на расстоянии от -3 до 3 от Ключ...

Сохранить
запрос

Коллокации ?

Скачать ?

Ключ	Коллокат	Совместная частота	Частота ключа	Частота коллоката	LogDice ▼	Loglikelihood ▼	MI ³ ▼	t-score ▼	Агр. мера ▼	Конкорданс
студент	бывший	565	44359	56556	9.51	3951.18	17.15	23.50	20.07	Примеры
студент	московский	635	44359	94414	9.31	3944.05	16.99	24.77	20.51	Примеры
студент	петербургский	216	44359	25047	8.92	1445.81	15.08	14.50	14.79	Примеры
студент	учебный	201	44359	21384	8.90	1379.69	15.02	14.01	14.50	Примеры
студент	медицинский	188	44359	19389	8.87	1302.01	14.92	13.55	14.22	Примеры
студент	молодой	619	44359	185875	8.77	2993.24	16.23	24.03	19.75	Примеры
студент	бедный	247	44359	55636	8.69	1330.56	14.68	15.31	14.99	Примеры
студент	старший	219	44359	59301	8.53	1101.05	14.26	14.34	14.30	Примеры
студент	киевский	116	44359	11476	8.52	812.77	13.99	10.65	12.21	Примеры
студент	политехнический	91	44359	2241	8.45	891.93	14.90	9.51	11.90	Примеры
студент	университетский	95	44359	6856	8.40	725.30	13.91	9.67	11.60	Примеры
студент	высший	190	44359	61862	8.37	887.33	13.79	13.27	13.53	Примеры
студент	дерптский	78	44359	582	8.34	958.20	15.78	8.82	11.80	Примеры

Портрет слова в НКРЯ

Скетчи ?

теория Существительное

Определения		Сказуемые		Глаголы с прямым дополнением		Глаголы с косвен	
1. квантовый	9.32	1. предсказывать	6.97	1. развивать	8.88	1. противоречи	
2. математический	8.32	2. объяснять	6.95	2. разработать	8.73	2. противопост	
3. эволюционный	8.22	3. существовать	6.38	3. излагать	8.57	3. увлекаться	
4. марксистско-ленинский	8.11	4. господствовать	6.22	4. разрабатывать	7.97	4. увлечься	
5. марксистский	8.04	5. возникнуть	6.08	5. изложить	7.91	5. руководствов	
6. научный	7.64	6. исходить	5.87	6. развить	7.83	6. следовать	
7. расовый	7.45	7. предполагать	5.86	7. создать	7.75	7. противопост	
8. экономический	7.37	8. гласить	5.84	8. опровергать	7.74	8. овладевать	
9. кинетический	7.34	9. являться	5.66	9. выдвинуть	7.61	9. разрушать	
10. классический	7.3	10. описывать	5.58	10. построить	7.49	10. вдохновлят	

Показать все коллокации

CoCoCo

- [CoCoCo](#) – ресурс для изучения сочетаемости слов русского языка
- Позволяет искать
 - коллокации (учет лексической сочетаемости)
 - коллигации (учет грамматической сочетаемости)
- Источники текстов – корпуса НКРЯ, ruWaC, Taiga
- Основан на нескольких принципах:
 - использование больших аннотированных корпусов русского языка;
 - анализ сочетаний слов с использованием статистических методов;
 - создание удобной системы обучения, генерирующей ответы на индивидуальные запросы.

- ☒ Таiga...
- ☐ НКРЯ
- ☐ I-RU

Введите слово

Введите слово

ЧАСТЬ РЕЧИ:

Все

ЧАСТЬ РЕЧИ:

Все

ТОКЕН ☐ лемма



ПОИСК

СБРОСИТЬ

Что по-русски делают **вслепую**?

Какой бывает **рука**?

Какие предлоги стоят после **говорить**?

ЧТО ИСКАТЬ?

Здесь вы найдёте ответы на эти и другие вопросы, связанные с сочетаемостью слов. Под сочетаемостью мы понимаем:

- модели управления («заниматься + творительный падеж», «из-за + родительный падеж», «просить + винительный или родительный падеж»);
- сочетания слов («тяжёлая болезнь», «печатать/идти/... вслепую»).

КАК ИСКАТЬ?

Введите слово в нужное поле (например, предлог «до») и нажмите «Поиск». Система покажет вам, какие слова и их грамматические особенности чаще всего встречаются рядом с заданным словом. Будьте терпеливы: иногда требуется пара минут, чтобы дождаться результата.

НУЖНА ПОМОЩЬ?

Смотрите раздел [ИНСТРУКЦИЯ](#).


Google Books Ngram Viewer

- [Google Books Ngram Viewer](#), [поисковый интерфейс на сайте корпусов Марка Дэвиса](#)
- [Инструкция по использованию](#)
- Использует следующие грамматические теги

NOUN		These tags can either stand alone (_PRON_) or can be appended to a word (she _PRON_)
VERB		
ADJ	adjective	
ADV	adverb	
PRON	pronoun	
DET	determiner or article	
ADP	an adposition: either a preposition or a postposition	
NUM	numeral	
CONJ	conjunction	
PRT	particle	
ROOT	root of the parse tree	These tags must stand alone (e.g., _START_)
START	start of a sentence	
END	end of a sentence	


Google Books Ngram Viewer

- Если вместо одного из слов поставить астериск, то будут показаны 10 самых частотных биграмм со вторым словом



Google Books Ngram Viewer

- Искать можно не только конкретные слова, но типичные сочетания с ними с учетом грамматических характеристик



Частотные списки

- составляются для
 - всего корпуса
 - подкорпусов авторов, жанров, периодов и т.п.
 - зоны заголовков, рифмовки в поэзии и т.п.
- могут представлять
 - словоформы, лексемы (леммы)
 - части речи, пунктуацию
 - буквы, сочетания букв
 - сочетания слов
(биграммы, триграммы – для словоформ и лемм)
 - (синтаксические) конструкции – более сложные запросы
 - пары синтаксически связанных слов (синтаксические биграммы)



Частотные списки – проблемы

- если слово встретилось в тексте один раз, то при нормальном распределении это не влияет на вероятность его употребления там во второй раз
- в реальности это не так: каждый текст имеет некоторую собственную тему, слова которой в этом тексте будут употребляться намного чаще среднего
- частотный список, построенный на основе некоторого корпуса, отражает специфику тех текстов, которые попали в него при его составлении
- корпус большего размера, отражающий большее количество тем и функциональных стилей, обеспечивает хорошую надежность для наиболее частотных элементов
- увеличение объема текстов в ущерб их разнообразию может приводить к меньшей надежности частотного списка на таких корпусах за счет сдвига их словаря в сторону определенной лексики

Объекты подсчета

You¹| simply²| cannot³| kill⁴| him⁵| before⁶| he⁷| kills⁸| you⁹| if¹⁰| you¹¹| rush¹²| токены

You¹| simply²| cannot³| kill⁴| him⁵| before⁶| he⁷| kills⁸| if⁹| rush¹⁰| типы

YOU¹| SIMPLY²| CAN³| NOT⁴| KILL⁵| HE⁶| BEFORE⁷| IF⁸| RUSH⁹ леммы

Токены, типы, леммы и лексемы

Определение слова	Преимущества	Недостатки
Тип	Легкое определение с высокой степенью достоверности	Отсутствует различие между формами с множеством грамматических функций и/или лексических значений
Лемма	Различение форм с разными грамматическими функциями	Требуется определения частеречной принадлежности и лемматизации (возможный источник ошибок)
Лексема	Самая точная категория; принимаются во внимание различия в лексическом значении	Определение с высокой степенью достоверности пока не доступно в полностью автоматическом режиме

Частотность и преподавание языка

- каким словам нужно учить в первую очередь – частотным или редким?
- тесты словарного запаса:
 - английский язык: <https://my.vocabularysize.com> или <https://www.vocabularytester.com>
 - русский язык: myvocab.info
- в основе – оценка знания слов разных групп частотности

Table 12.1 EFL vocabulary size, formal EFL exams and the CEFR (from Meara and Milton, 2003, p. 5)

<i>CEFR level</i>	<i>Cambridge exam</i>	<i>XLex score (max. 5000)</i>
A1	Starters, Movers and Flyers	<1500
A2	Key English Test (KET)	1500–2500
B1	Preliminary English Test (PET)	2750–3250
B2	First Certificate in English (FCE)	3250–3750
C1	Cambridge Advanced English (CAE)	3750–4500
C2	Cambridge Proficiency in English (CPE)	4500–5000

Случай с Оливером

(пример Р. М. Фрумкиной)

- Заглонитель Ланс Оливер чуть не погиб в результате напличения турма. Он ехал ласкунно на лошади покровнательно от Мэнсфилда (Австралия) и увидел вахню турмов, в которой было кастожно 15 животных. Столенно, ничего бы и не случилось, если бы собака Оливера не начала порочить на вахню.
- Один из турмов – старый, крупный лователь, выбатушенный корочением собаки, бросился за ней. Та отпешила скумановаться за лошадьё, на которой сидел Оливер. Тогда турм бросился уже на Оливера. Он схватил подвешенца отмаленными твинами за плечи и вытокнул его на землю.

Случай с Оливером

(пример Р. М. Фрумкиной)

- Скотовод Ланс Оливер чуть не погиб в результате нападения кенгуру. Он ехал верхом на лошади неподалеку от Мэнсфилда (Австралия) и увидел стадо кенгуру, в котором было примерно 15 животных. Возможно, ничего бы и не случилось, если бы собака Оливера не начала лаять на стадо.
- Один из кенгуру – старый крупный самец, раздраженный лаем собаки, бросился за ней. Та попыталась укрыться за лошадьё, на которой сидел Оливер. Тогда кенгуру бросился уже на Оливера. Он схватил всадника передними лапами за плечи и сбросил его на землю.

Случай с Оливером (пример Р. М. Фрумкиной)

- в этом тексте заменены вымышленными слова, которые ниже 2500-го места по частотности в частотном словаре русского языка Э.А. Штейнфельдт
- используя частотные словари, можно выбрать слова, значения которых надо выучить в первую очередь
- некоторые частые слова не находят себе место в начале списков частотных словарей
- абсолютное большинство частотных словарей составляется на основе письменной речи

<https://www.wordandphrase.info>

 Corpus of Contemporary American English          

SEARCHFREQUENCYCONTEXTANALYZE TEXT

EDIT TEXTSAVE TEXT

☒ WORD☐ PHRASE

FREQ RANGE	1-500	501-3000	> 3000
261 WORDS	62 %	12 %	13 %

CLICK ON ANY WORD BELOW FOR A FULL WORD SKETCH

Mr. and Mrs. **Dursley**, of number four, Privet Drive, were **proud** to say that they were **perfectly normal**, thank you very much. They were the last people you'd expect to be **involved** in anything **strange** or **mysterious**, because they just didn't hold with such **nonsense**. Mr. **Dursley** was the **director** of a **firm** called Grunnings, which made **drills**. He was a big, **beefy** man with **hardly** any **neck**, although he did have a very large **mustache**. Mrs. **Dursley** was **thin** and **blonde** and had **nearly twice** the **usual** amount of **neck**, which came in very **useful** as she spent so much of her time **craning** over **garden fences**, **spying** on the **neighbours**. The Dursleys had a small **son** called Dudley and in their **opinion** there was no **finer** boy **anywhere**. The Dursleys had everything they wanted, but they also had a **secret**, and their **greatest fear** was that **somebody** would **discover** it. They didn't think they could **bear** it if **anyone** found out about the Potters. Mrs. **Potter** was Mrs. **Dursley's sister**, but they hadn't met for several years; in fact, Mrs. **Dursley pretended** she didn't have a **sister**, because her **sister** and her **good-for-nothing husband** were as **unDursleyish** as it was **possible** to be. The Dursleys **shuddered** to think what the **neighbours** would say if the Potters **arrived** in the street. The Dursleys knew that the Potters had a small **son**, too, but they had never even seen him. This boy was another good reason for keeping the Potters away; they didn't want Dudley **mixing** with a child like that.

(CLICK ANY WORD FOR FULL WORD SKETCH)

LOW FREQ	MID FREQ	HIGH FREQ
5: dursley 1: anywhere, beefy, blonde, craning, drills, fences, good-for-nothing, mustache, mysterious, nonsense, perfectly, potter, pretended, proud, shuddered, spying, undursleyish, useful, usual	3: sister 2: neck, neighbours, son 1: amount, anyone, arrived, bear, director, discover, fear, finer, firm, garden, greatest, hardly, husband, involved, mixing, nearly, normal, opinion, possible, secret, somebody, strange, thin, twice	14: the 10: they 8: a, was 7: had 6: and 5: did, in, n't 4: of, that, to, were 3: as, but, her, it, very, with 2: be, because, boy, called, for, have, he, if, much, say, she, small, their, think, which, would, you 1: about, also, although, another, any, anything, away, big, came, child, could, even, everything, expect, fact, found, four, good, him, hold, just, keeping, knew, large, last, like, made, man, met, never, no, number, on, or, out, over, people, reason, seen, several, so, spent, street, such, thank, there, this, time, too, want, wanted, what, years

https://textometr.ru/

Анализ сложности текста Проверка частотности слов Ёфик

Анализ сложности текста

Текстометр помогает определить уровень сложности и читабельности текста, посчитать количество слов и знаков, найти среднюю длину слова и предложения, ключевые слова текста, рассчитать коэффициент лексического разнообразия текста, получить список слов текста и рассчитать время его чтения.

Русский как иностранный



Русский как родной

Мистер и миссис Дурсль проживали в доме номер четыре по Тисовой улице и всегда с гордостью заявляли, что они, слава богу, абсолютно нормальные люди. Уж от кого-кого, а от них никак нельзя было ожидать, чтобы они попали в какую-нибудь странную или загадочную ситуацию. Мистер и миссис Дурсль весьма неодобительно относились к любым странностям, загадкам и прочей ерунде.

Мистер Дурсль возглавлял фирму под названием «Граннингс», которая специализировалась на производстве дрелей. Это был полный мужчина с очень пышными усами и очень короткой шеей. Что же касается миссис Дурсль, она была тощей блондинкой с шеей почти вдвое длиннее, чем положено при ее росте. Однако этот недостаток пришелся ей весьма кстати, поскольку большую часть времени миссис Дурсль следила за соседями и подслушивала их разговоры. А с такой шеей, как у нее, было очень удобно заглядывать за чужие заборы. У мистера и миссис Дурсль был маленький сын по имени Дадли, и, по их мнению, он был самым чудесным ребенком на свете.

Семья Дурслей имела все, чего только можно пожелать. Но был у них и один секрет. Причем больше всего на свете они боялись, что кто-нибудь о нем узнает. Дурсли даже представить себе не могли, что с ними будет, если выплывет правда о

Определить

[Вставить демо текст](#)

[Очистить](#)

39 баллов из 100. Простой текст, подойдет для возраста 9-10 лет (3-4 класс).

Структурная сложность	4 из 10
Лексическая сложность	5 из 10
Динамичность текста	6 из 10
Описательность текста	3 из 10
Знаков с пробелами	1751
Предложений	18
Слов	281
Уникальных слов	167
Средняя длина слова	5.1
Средняя длина предложения	15.6
Формула Флеша	65 из 100 (чем больше - тем текст легче)
Формула Флеша-Кинкейда	9 (примерно должна соответствовать школьному классу)
Лексическая плотность ②	6 из 10
Лексическое разнообразие ②	0.59
Список Русский детский 5000 ②	84 %
Редкие слова	содрогаться выплывать тисовый дурслей положено дрель миссис дурсль граннингс неодобительно никчемный

Macmillan dictionary

- ★★★ – 1–2500 места в частотном списке (book, animal)
- ★★ – 2501–5000 места в частотном списке (appropriate, tragedy)
- ★ – 5001–7500 места в частотном списке (restriction, allegedly)
- без звездочек – остальные (crescent, thatch)

edge¹ /edʒ/ noun ★★★

- | | |
|----------------------------|-------------------|
| 1 part furthest out | 4 advantage |
| 2 sharp side of blade/tool | 5 strange quality |
| 3 angry tone in voice | + PHRASES |

1 [C] the part of something that is furthest from its centre: *Bring the two edges together and fasten them securely.* ♦ **+of** *The railway station was built on the edge of town.* ♦ *Victoria was sitting on the edge of the bed.*

2 [C] the sharp side of a blade or tool that is used for cutting things: *the knife's edge*

3 [singular] a quality in the way that someone speaks that shows they are becoming angry or upset: **+to/in** *Had she imagined the slight edge to his voice?*

4 [singular] an advantage that makes someone or something more successful than other people or things: **give sb/sth an/the edge over sb/sth** *Training can give you the edge over your competitors.*

5 [singular] a strange quality that something such as a piece of music or a book has that makes it interesting or exciting: *There is an edge to his new album that wasn't there in the last one.*

PHRASES **live on the edge** to have a life with many dangers and risks, especially because you like to behave in a reckless and unusual way: *Despite the apparent*

Частотные словари

- вид словаря (обычно одноязычного), в котором лексические единицы характеризуются с точки зрения степени их употребительности в совокупности текстов, представительных для языка в целом, отдельного функционального стиля либо одного автора
- информацию о каких словах следует включать? как выделять значимые слова?
- каким образом оценивать информацию о частотности слова, полученную на материале конкретного корпуса?
- как и из чего собирать корпус для составления частотного словаря?

Частотные словари русского языка

- Йоссельсон Г. Словарь русского языка. Детройт, 1953 (Josselson H.H. The Russian word count... Detroit, 1953) (в основном на материале языка дореволюционной России, объем словника – 1700 слов, обработка 1 млн словоупотреблений)
- Штейнфельдт Э.А. Частотный словарь современного русского литературного языка. Таллин, 1963 (2 500 наиболее употребительных слов, обработка 400 тыс. словоупотреблений)
- Частотный словарь русского языка: Около 40 000 слов / Под ред. Л.Н. Засориной. М., 1977 (обработка средствами вычислительной техники 1 млн словоупотреблений)
- Лёнгрен Л. Частотный словарь современного русского языка. Uppsala, 1993 (обработка средствами вычислительной техники 1 млн словоупотреблений)
- Ляшевская О.Н., Шаров С.А. Частотный словарь современного русского языка (на материалах Национального корпуса русского языка). М.: Азбуковник, 2009 (обработка средствами вычислительной техники 92 млн словоупотреблений)

Самые частотные русские слова

О. Н. Ляшевская, С. А. Шаров
НОВЫЙ ЧАСТОТНЫЙ СЛОВАРЬ РУССКОЙ ЛЕКСИКИ

Электронная версия издания:
О. Н. Ляшевская, С. А. Шаров, Частотный словарь современного русского языка (на материалах Национального корпуса русского языка). М.: Азбуковник, 2009.

Как пользоваться словарем

[Вернуться к содержанию](#)

Частотный список лемм

	Лемма	Лемма	Часть речи	Частота (ipm)	Худ.лит.1950-60-е	1970-80-е	1990-2000-е	Публ. 1950-60-е	1970-80-е	1990-2000-е
1	и	и	conj	35801.8	37546.0	39187.7	36514.7	36703.6	38352.1	35539.5
2	в	в	pr	31374.2	23943.5	25005.7	26185.7	35295.3	33264.3	36372.5
3	не	не	part	18028.0	21154.3	22921.5	22349.1	16127.4	18796.9	16853.2
4	на	на	pr	15867.3	17169.9	16411.7	16663.0	15249.8	15961.9	16675.2
5	я	я	spro	12684.4	17022.7	17090.5	18257.0	13881.5	16386.7	10447.1
6	быть	быть	v	12160.7	12467.9	13492.8	12778.1	14458.2	15091.8	12646.0
7	он	он	spro	11791.1	19708.0	18587.1	16882.0	11721.6	12799.3	8811.7
8	с	с	pr	11311.9	11186.1	10974.4	11655.3	11060.5	11662.5	11462.7
9	что	что	conj	8354.0	8155.2	8313.9	8938.8	7634.5	9702.4	8743.1
10	а	а	conj	8198.0	10298.0	10772.2	9897.5	5748.9	7643.3	7298.8
11	по	по	pr	5786.7	4506.0	4616.7	4840.0	5059.6	5353.8	6656.1
12	это	это	spro	5707.8	6038.4	6137.5	5946.6	5378.3	6614.3	5831.8
13	она	она	spro	5592.4	8375.6	8348.8	9474.0	5302.7	4673.6	3733.1
14	этот	этот	apro	5414.0	5140.8	4817.3	4723.1	6032.0	6689.8	5919.4
15	к	к	pr	5389.0	5698.6	5318.7	5363.7	5874.9	5954.7	5341.7
16	но	но	conj	5381.4	5698.3	6201.0	6256.6	5234.5	6324.1	5597.2
17	они	они	spro	4850.0	5869.7	5636.6	5358.9	4683.0	5658.6	4788.9
18	мы	мы	spro	4704.8	4525.6	4482.9	4194.8	5424.2	8155.8	5241.8
19	как	как	conj	4403.7	4658.0	4819.5	4948.4	4149.3	4650.9	4248.5
20	из	из	pr	4314.1	3804.5	3846.3	4290.8	4634.1	4804.2	4774.0

Сравнительная частота слов по корпусам и частотным словарям (ipm)

Лемма	Лённгрен	Засорина	Штейнфельдт	НКРЯ	ruWaC
власть	202	364	138	422	428
думать	609	1094	1058	865	818
загрязнение	69	1	0	9	11
задача	499	421	250	228	292
изучение	193	110	0	63	78
любить	415	632	595	549	650
милый	58	242	135	129	110

Введение к Частотному словарю современного русского языка (на материалах Национального корпуса русского языка) / Ляшевская О.Н., Шаров С.А. – М.: Азбуковник, 2009

Частотные словари английского языка

- Francis W., Kučera H. Frequency Analysis of English Usage. Boston, 1982
- John B. Carroll, Peter Davies, & Barry Richman. The American Heritage Word Frequency Book
- Mark Davies, Dee Gardner. A Frequency Dictionary of American English: Word Sketches, Collocates, and Thematic Lists. Routledge, 2010

Самые частотные английские слова

1 6187267 the det	2 4239632 be v	3 3093444 of prep
4 2687863 and conj	5 2186369 a det	6 1924315 in prep
7 1620850 to infinitive-marker	8 1375636 have v	9 1090186 it pron
10 1039323 to prep	11 887877 for prep	12 884599 i pron
13 760399 that conj	14 695498 you pron	15 681255 he pron
16 680739 on prep	17 675027 with prep	18 559596 do v
19 534162 at prep	20 517171 by prep	21 465486 not adv
22 461945 this det	23 459622 but conj	24 434532 from prep
25 433441 they pron	26 426896 his det	27 384313 that det
28 380257 she pron	29 373808 or conj	30 372031 which det
31 364164 as conj	32 358039 we pron	33 343063 an det
34 333518 say v	35 297281 will modal	36 272345 would modal
37 266116 can modal	38 261089 if conj	39 260919 their det
40 249540 go v	41 249466 what det	42 239460 there pron
43 230737 all det	44 220940 get v	45 218258 her det
46 217268 make v	47 205432 who pron	48 201968 as prep
49 201819 out adv	50 195426 up adv	51 191661 see v

Проблемы определения частотности

- искажение выборки текстов из-за ее несбалансированности (Journal of Gastroenterology and Hepatology – 713 тыс. слов в BNC)
- другие значения и конструкции (*banana skin* vs *banana republic*)
- проблема моллюсков (*whelk-gastric problem*) и проблема зубных щеток (*banana-toothbrush problem*)
- наличие выбросов (*outlier* = *frequency burst* vs *frequency drop*)
- неравномерно распределенные по корпусу слова (*overdispersed words*)
 - слова, часто встречающиеся в одном тексте (НКРЯ – *веснянка*, *якорь*, BNC – *whelk*, *gastric*, *peptides*)
 - слова, встретившиеся в одном-двух текстах (*спунеризм*)
 - стоп-слова, часто встречающиеся во всех текстах (*и*, *на*, *этот*, *the*, *be*, *to*...)
 - не-слова: (*аровыларол*, *егкишугзекшущ*...)

Просто поразительно! Как вы получаете такие крутые показатели?



Частота встречаемости


- частота встречаемости
 - абсолютная (общее количество примеров в корпусе)
 - относительная (в процентах от объема корпуса) vs нормализованная (на миллион словоупотреблений)
- f – абсолютная частотность
- $\frac{f(x)}{N}$ – относительная частотность,
- где N – число исследованных слов текста (объем корпуса), f – количество найденных примеров

Частотное поведение слова

- ipm (items / instances per million) – количество употреблений токена на миллион словоупотреблений
 - стандартное представление частотности токена, вычисляемое относительно условного корпуса в миллион единиц независимо от объема реального корпуса
- $$\text{ipm}(x) = \frac{f(x)}{N} \times 1\,000\,000,$$
- где $f(x)$ – частотность единицы в корпусе, N – объем корпуса
- лемма *телефон* (пример А.Ч. Пиперски)
- Толстой – 9 вхождений, Рыбаков – 6 вхождений
- объем корпуса текстов: Толстой – 1 906 467 слов, Рыбаков – 180 583 слов
- частотность леммы *телефон*: Толстой – 5 ipm, Рыбаков – 33 ipm


Закон Ципфа

- эмпирическая закономерность распределения частоты слов естественного языка: если все слова языка (корпуса, достаточно длинного текста) упорядочить по убыванию частоты их использования, то частота n -го слова в таком списке окажется примерно обратно пропорциональной его рангу (порядковому номеру)
- $\Rightarrow$ второе по частоте слово встречается $\sim$ в 2 раза реже, чем первое, третье $\sim$ в 3 раза реже, чем первое, и т.п.
- если закон Ципфа соблюдается, то перед вами нормальный текст на естественном языке
- $\text{freq}(w) \times \text{rank}(w)^\gamma = \text{Const}$




Закон Ципфа

- γ – поправка Б. Мандельброта (1965) к закону Дж.К. Ципфа (1949)
- Б. Мандельброт выделил голову (стоп-слова), среднюю часть и хвост (гапаксы) графика – broken power law
- на материале больших веб-корпусов этот закон выполняется примерно для половины слов
- для морфологически богатых языков (ср. также словоформы – леммы) скорость убывает иначе
- $\text{freq}(w) \times (\text{rank}(w) + \beta)^\gamma = \text{Const}$






Частотные списки и закон Ципфа

Ранг	Слово	Абсолютная частотность	Относительная частотность (на 1 млн слов)
1.	the	6,041,234	61,448.72
2.	of	3,042,376	30,945.68
3.	and	2,616,708	26,615.98
4.	to	2,593,729	26,382.25
5.	a	2,164,238	22,013.66
6.	in	1,937,819	19,710.62
7.	that	1,118,985	11,381.81
8.	it	1,054,279	10,723.65
9.	is	990,281	10,072.69
10.	was	881,473	8,965.95



Частотные списки и закон Ципфа



Меры изменчивости

- размах – разность между самым большим и самым маленьким значением
 - межквартильный размах – разность между самым большим и самым маленьким значением после удаления 25 % самых больших и самых маленьких значений
- отклонение – разность между средним арифметическим и конкретным значением переменной
- дисперсия – среднее арифметическое от квадратов отклонений

Меры изменчивости

- стандартное отклонение – квадратный корень из дисперсии
 - стандартное отклонение генеральной совокупности (среднеквадратическое отклонение) – квадратный корень из дисперсии по генеральной совокупности
 - $S = \sqrt{\frac{\sum(x - \bar{x})^2}{n}}$
 - стандартное отклонение выборки – квадратный корень из дисперсии по выборке
 - $\sigma = \sqrt{\frac{\sum(x - \bar{x})^2}{n-1}}$
- где x – наблюдаемое значение, $\bar{x}$ – среднее арифметическое от всех значений
- чем меньше цифра, тем более плотно и равномерно распределены лексемы


Меры изменчивости

- Стандартное отклонение


$$S = \sqrt{\frac{\text{сумма квадратов расстояний от среднего арифметического}}{\text{количество частей корпуса}}}$$

Меры изменчивости

- Стандартное отклонение




Дисперсия / разброс / распространенность (dispersion)



Меры распространённости (measures of dispersion)

- задача частотного словаря – не просто ранжировать слова по их частоте в отдельном корпусе, но и определить лексическое ядро языка
- необходимо отделить слова, часто встречающиеся во многих текстах, от тех, чье лексическое поведение подобно словам *сепульки* или *хоббит* и которые случайно оказались в той или иной позиции частотного списка



R (Range)

- R (range) – количество сегментов корпуса, в которых встретилось слово, из общего числа сегментов n (в словаре Ляшевской и Шарова $n = 100$)
- недостаток R – вычисляется на небольшом (для размера корпуса) количестве сегментов $\Rightarrow$ слишком небольшое множество возможных значений (целые числа от 0 до n)

R (Range)

- Range = количество сегментов корпуса со словом w

	Section 1	Section 2	Section 3	Section 4	Section 5	Section 6
Word w						5
Includes w ?	YES	YES	YES	NO	YES	YES

Range(w) = 5

D Жуйана (Juilland's D)

- коэффициент D, введенный А. Жуйаном [Juilland et al. 1970], принимает во внимание как число документов, в которых встречается слово, так и его относительную частоту в этих документах

- $$D = 100 \times \left(1 - \frac{\sigma}{\bar{v}\sqrt{n}}\right) \quad \sigma = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (v_i - \bar{v})^2}$$

- где μ – средняя частота слова по всему корпусу, σ – среднее квадратичное отклонение этой частоты на отдельных документах, n – число документов, в которых встречается это слово
- значение D у слов, встречающихся в большинстве документов, близко к 100, а у слов, часто встречающихся лишь в небольшом числе документов, близко к 0

D Жуйана

- D Жуйана

$$= 1 - \frac{\frac{\text{стандартное отклонение}}{\text{среднее арифметическое}}}{\sqrt{\text{число сегментов корпуса} - 1}}$$


наблюдаемая вариативность

максимальная возможная
вариативность

D Жуйана

- D Жуйана

$$\text{Juilland's } D = 1 - \frac{0.91}{\sqrt{6-1}} \cong 0.59$$



- если слова *мерзкий*, *рисовать* и *конунг* имеют примерно равную частоту (21 ipm), но при этом коэффициент D у *рисовать* – 66, *конунг* – 18, а у *мерзкий* – 78, это означает, что последнее слово значимо для большего числа предметных областей и (при прочих равных условиях) имеет большие шансы на место в неспециализированном словаре

Комбинации R и D


- высокое R, высокое D – лексическое ядро языка
- высокое R, низкое D – слово есть во всех сегментах, но с очень разными частотами $\Rightarrow$ общая частотность завышена
- низкое R, высокое D – низкочастотное слово, периферия языка
- низкое R, низкое D – тематически окрашенное слово
 - *якорь* (словарь Ляшевской и Шарова): 25,9 ірм, R = 91; D = 28
8.190 вхождение в НКРЯ / 374 млн = 21,9 ірм
 - 1750 из них в тексте Л.Н. Скрягина «Книга о якорях»
 - $1750 / 46\,179 = 37\,896$ ірм;
ср. союз *и*: $1405 / 46179 = 30\,400$ ірм

Усовершенствованные меры частотности

- усовершенствованные меры частотности
 - Average Reduced Frequency
 - Average Waiting Time
 - Average Logarithmic Distance
- решение – делить корпус на нефиксированное количество сегментов $\Rightarrow$ для разных слов выделяется разное количество сегментов, тогда:
 - корпус – закольцованный список слов длины N (пронумерованный от 1 до N)
 - f – число вхождений в корпус слова w
 - p_i – позиция i -го вхождения слова w
 - d_i – расстояние от $(i - 1)$ -го до i -го вхождения слова w
- лекция А.Ч. Пиперски о мере ARF

Reduced Frequency

- разделим корпус на f сегментов длины $v = N / f$ (NB: R у Ляшевской и Шарова делит корпус на равное число сегментов для всех слов)
- Reduced Frequency (RF) – количество сегментов, содержащих слово w хотя бы 1 раз
- $RF_{\max} = f$
- $RF_{\min} = \lceil f / v \rceil = \lceil f / (N / f) \rceil = \lceil f^2 / N \rceil$



$$N = 20, f = 5, v = 4$$


$$RF = 4$$

Average Reduced Frequency

- формула для измерения средней уменьшенной частоты (average reduced frequency, ARF) [[Savický & Hlaváčová 2002](#)]
- $ARF = \frac{1}{v} \sum_{j=1}^v RF_j = \frac{1}{v} \sum_{i=1}^f \min\{d_i, v\}$
- где v – длина одной части корпуса, d – расстояние между двумя словоформами лексемы в корпусе ($d_i = n_i - n_{i-1}$), n – позиция нужных слов, f – количество частей

Average Reduced Frequency

- разбиение на сегменты не обязано начинаться с первого слова $\Rightarrow$ надо брать усредненную RF по всем разбиениям на сегменты
- имеет смысл вычислять RF только для сегментов с 1-го до v -го, потому что, начав с $(v + 1)$ -го, получим такое же разбиение, как с 1-го, и т. д.
- невозможно перебирать все разбиения корпуса для всех слов
- не больше v сегментов начиная с $(n_{i-1} + 1)$ -го по n_i содержат слово w





$$ARF = (4 + 3 + 3 + 5) / 4 = 3,75$$

Average Reduced Frequency

- $ARF = \frac{1}{v} \times (\min(\text{distance}_1, v) + \min(\text{distance}_2, v) + \min(\text{distance}_3, v) \dots)$

где $v = \frac{\text{общее количество токенов}}{\text{абсолютная частотность слова}}$



Абсолютная частотность = 5

Ключевые слова (keywords)

Positive keywords +

Lockwords

Negative keywords –

Фокусный корпус С	Референсный корпус R	Вывод
высокочастотное	низкочастотное	+ (positive keyword)
низкочастотное	высокочастотное	– (negative keyword)
сопоставимая частота	сопоставимая частота	o (lockword)

Ключевые слова

Log likelihood	SMP (with 100 as the constant)	Log ratio	Cohen's d
U.S.	U.S.	LABOR	TOWARD
PERCENT	PERCENT	NEIGHBORHOOD	NEIGHBORHOOD
AMERICAN	PROGRAM	DEFENSE	RECOGNIZE
PROGRAM	TOWARD	CONGRESSIONAL	NEIGHBORS
TOWARD	AMERICAN	ATLANTA	COLORED
STATES	BUSH	PGF2A	MANHATTAN
FEDERAL	FEDERAL	MACDOWELL	FAVORITE
BUSH	STATES	MRNA	RECOGNIZED
PRESIDENT	CENTER	NEIGHBORS	CENTER
CENTER	MR.	ABBY	REALIZE
MR.	PRESIDENT	GENOME	RECOGNIZING
PROGRAMS	PROGRAMS	FLORIDA	TRAVELED
UNITED	UNITED	9-11	SIGNALLED
STATE	WASHINGTON	DOE	COLOR
CONGRESS	CONGRESS	POE	CALIFORNIA
WASHINGTON	AMERICANS	ROUSSEAU	GOTTEN
AMERICANS	STATE	NS1	LABOR
DEFENSE	CALIFORNIA	REZKO	FAVOR
CALIFORNIA	AMERICA	MITCH	FINALLY
WAR	DEFENSE	ADDITIVES	CENTERS

$$\log \text{likelihood}_{\text{short}} = 2 \times \left(O_{11} \times \log \frac{O_{11}}{E_{11}} + O_{21} \times \log \frac{O_{21}}{E_{21}} \right)$$

$$\text{simple maths parameter} = \frac{\text{relative frequency of } w \text{ in } C + k}{\text{relative frequency of } w \text{ in } R + k}$$

Log-likelihood

	Подкорпус	Другие тексты	Весь корпус
Частота	a	b	a+b
Размер	c	d	c+d

На основе этой матрицы значение отношения правдоподобия G^2 (LL-score) можно вычислить как:

$$= 2(a \ln(\frac{a}{E1}) + b \ln(\frac{b}{E2})); \text{ где } E1 = c \frac{a+b}{c+d}; E2 = d \frac{a+b}{c+d}$$

Здесь a , b , c , d – наблюдаемые величины, а $E1$ и $E2$ – ожидаемый показатель в сравниваемых подкорпусах (см. Rayson & Garside 2000).

Keyness

- позволяет оценить, насколько слово характерно для данного подкорпуса и насколько оно нехарактерно для контрастного подкорпуса
- частотная мера keyness: $K = \frac{a/c}{b/d}$
- версия Add-N keyness: $K = \frac{f_{foc}/T_{foc} + N}{f_{ref}/T_{ref} + N}$
- где f_{foc} – количество вхождений слова в фокусном подкорпусе, T_{foc} – объем фокусного корпуса, f_{ref} – количество вхождений слова в референсном корпусе, T_{ref} – объем референсного корпуса, N – некоторое число
- помогает в случае, если $b = 0$, сглаживает частотные эффекты: при $N = 1$ выше будут ранжированы редкие слова, при $N = 1000$ выше будут ранжированы высокочастотные слова

TF-IDF

- **TF*IDF** (term frequency – inverse document frequency) – мера, позволяющая выделить наиболее важные слова для документа относительно всего корпуса
- TF*ICTF (term frequency – inverse collection term-frequency)

$$\text{TF*ICTF} = \frac{f_d}{F_d} * \log \frac{F_D}{f_D}, \text{ где}$$

f_d – количество анализируемых словоформ/лемм (term) в документе,

F_d – количество всех словоформ/лемм в анализируемом документе,

F_D – общее количество словоформ/лемм контрастном подкорпусе,

f_D – количество анализируемых слов/лемм контрастном подкорпусе.

- модифицированная

$$\text{TF*ICTF}' = (0,5 + 0,5 \frac{f_d}{F_d}) * \log \frac{F_D - F_d}{f_D - f_d}, \text{ где}$$

$F_D - F_d$ – объем контрастного подкорпуса без объема документа, в которую входит единица, для которой вычисляется вес,

$f_D - f_d$ – количество анализируемой словоформы в контрастном подкорпусе, кроме количества словоформы в документе, в которую входит анализируемая единица⁹.

TF-IDF

TF-IDF is a measure of originality of a word by comparing the number of times a word appears in a doc with the number of docs the word appears in.

$$\text{TF-IDF} = \text{TF}(t, d) \times \text{IDF}(t)$$

Term frequency

Number of times term t appears in a doc, d

Inverse document frequency

$$\log \frac{1 + \overset{\text{\# of documents}}{n}}{1 + \underset{\text{Document frequency of the term } t}{df(d, t)}} + 1$$

Использованные материалы

- <https://corpus-stats.lancs.ac.uk>
- <https://seeing-theory.brown.edu>
- <https://www.rawgraphs.io>
- <https://datatab.net>
- <http://vassarstats.net>
- <https://www.socscistatistics.com>
- <https://www.graphpad.com>
- <https://www.statology.org/calculators/>
- <https://jasp-stats.org>
- <https://www.jamovi.org>
- <https://www.gnu.org/software/pspp/>
- <https://spssgratis.com/en/spss-for-students/>