

Как заговорить с корпусом на его языке: регулярные выражения для переводчиков



Ирина Евгеньевна Пинхасик, РГГУ / МГЛУ

Зимняя школа перевода СПР, 29–31 января 2025 г.



Это я

Ирина Евгеньевна Пинхасик

ст. преп. учебно-научного центра
компьютерной лингвистики
Института лингвистики РГГУ

ст. преп. кафедры скандинавских,
нидерландского и финского языков
Переводческого факультета МГЛУ

переводчик с чешского и
болгарского

fablecraft@gmail.com,
vk, tg @butanojoou

Материалы лекции



Операторы поиска в НКРЯ

- | – или (то, что слева, или то, что справа)
- () – группировка слов
- - – отрицание
- * – замена части слова (ноль или более символов)
- & – объединение признаков
- " " – точный поиск

Подстановочные знаки (wildcards)

- работают при простом поиске
- ? – один символ, может повторяться и употребляться в любой части слова
 - ?винья, ??инья, ???нья
 - свинь?, свинь??, свинь???
- | – или (то, что слева, или то, что справа)
 - кошка | кот | котенок (наличие или отсутствие пробелов зависит от корпуса)
- * – замена части слова (ноль или более символов), может употребляться в любой части слова
 - перевод*, *чик, пер*чик
- -- – тире, пробел или отсутствие символа
 - научно--образный
- NB: для поиска астериска и вопросительного знака используется знак \, например * и \?

Регулярные выражения (regular expressions)

- формальный язык для осуществления операций со строками (поиск, замена и т.п.), основанный на использовании метасимволов
- для поиска используется строка-образец (шаблон, маска, паттерн), состоящая из символов и метасимволов и задающая правило поиска
 - если есть выражение и какая-либо строка (слово, массив текстов, записи в полях базы данных и т.д.), то операцию проверки, удовлетворяет ли строка выражению, называют сопоставлением строки и выражения
 - если какая-то строка или часть строки успешно сопоставилась с выражением, это называется совпадением (соответствием)

I (love | hate)
RegEx

Плюсы, минусы, подводные камни

- позволяют задавать самые разные поисковые запросы
 - все варианты названия профессии «риелтор» (риелтор, риелтер, риэлтер, риэлтор)
 - все четырехзначные даты в тексте (или те из них, после которых следует слово год)
 - все почтовые ящики на российских доменах (vasya1999@yandex.ru или petya2001@mail.ru, но не krtekhrad@gmail.com или obhajoba@seznam.cz)
 - все формы какого-либо слова (суслик, суслика, суслику, суслики и т.п., но не сусликовый)
 - все повторы одного слова (любого)
 - все слова, которые начинаются на на- и кончаются на -ся (напиться, наестся, наплакаться, нагуляться, надуться, напереводиться)
 - все теги/атрибуты/комментарии в HTML-коде...
- могут выглядеть страшно $\wedge \backslash + \backslash d\{1,3\} \backslash (\backslash d\{3\} \backslash) (| -) ? \backslash d\{3\} (| -) ? \backslash d\{2\} (| -) ? \backslash d\{2\} \$$
- бывает сложно сразу правильно написать или отладить

«Муаммар Каддафи»

$$M \begin{cases} u \\ o \\ ou \end{cases} \begin{cases} \emptyset \\ , \end{cases} \begin{cases} \emptyset \\ a \end{cases} \begin{cases} mm \\ m \end{cases} ar \begin{cases} Al \\ al \\ El \\ el \\ \emptyset \end{cases} \begin{cases} - \\ _ \\ \emptyset \end{cases} \begin{cases} Q \\ G \\ K \\ Kh \end{cases} a \begin{cases} d \\ dh \\ dd \\ dhdh \\ th \\ zz \end{cases} \begin{cases} f \\ ff \end{cases} \begin{cases} i \\ y \end{cases}$$

M(u|ou?)'a?mm?ar

((A|a|E|e)l)?-?

(Q|G|Kh?)a(d(d|h(dh)?)|th|zz)ff?(i|y)


Управляющие команды

- простые символы, а также управляющие символы, играющие роль их заменителей;
- управляющие конструкции (квантификаторы повторений, оператор альтернативы, группирующие скобки и т.д.);
- мнимые символы (в строке их нет, но они помечают какую-то часть строки)



Обычные символы и метасимволы

- обычные символы – соответствуют сами себе
 - буквы любого алфавита
 - цифры
 - некоторые знаки пунктуации
- метасимволы – не соответствуют сами себе
 - `. * + ? { } [ ] \ | ( ) ^ $`



FALSEKNEES©2020

Метасимволы

- . – любой символ, может повторяться и употребляться в любой части слова
 - к.т, к.шка, к.тенок
 - пс., пс., пс...
 - .т..с, ..нк., х..
- регулярное выражение, которое сопоставится со словами
 - *вупсень и пупсень*
 - *бабы, биба и боба*
 - *кешбек, кешбэк, кэшбек и кэшбэк*
 - *перевод, переход и переток*

Количественные операторы (квантификаторы)

- ? – предыдущий символ/группа может быть, а может не быть
- + – предыдущий символ/группа может повторяться 1 и более раз
- * – предыдущий символ/группа может повторяться 0 и более раз
- {n, m} – предыдущий символ/группа может повторяться от n до m раз
- {n,} – предыдущий символ/группа в скобках может повторяться n и более раз
- {,m} – предыдущий символ/группа может повторяться до m раз
- {n} – предыдущий символ/группа повторяется n раз

Количественные операторы (квантификаторы)

- ? – предыдущий символ/группа может повторяться 0 или 1 раз
 - *хр..?*, *к?р?от*, *пыль?*, *..?дал*
- * – предыдущий символ/группа может повторяться 0 и более раз
 - *кот.**, *.*кот*, *.*кот.**, *ко*т*, **от*
- + – предыдущий символ/группа может повторяться 1 и более раз
 - *..+ешь.+*, *п.+на*, *сло+во*
- регулярное выражение, которое сопоставится со словами,
 - начинающимися на *за*
 - заканчивающимися на *кость*
 - начинающимися на *пол* и заканчивающимися на *ник*
 - содержащими последовательность символов *пир*

Количественные операторы (квантификаторы)

- $\{n, m\}$ – предыдущий символ/группа может повторяться от n до m раз
- $\{n, \}$ – предыдущий символ/группа в скобках может повторяться n и более раз
- $\{,m\}$ – предыдущий символ/группа может повторяться до m раз
- $\{n\}$ – предыдущий символ/группа повторяется n раз
- регулярное выражение, которое сопоставится со словами
 - *фrrrr, mrrr и brrr*
 - *хм, хмм и хmmm*

Выбор и группировка СИМВОЛОВ

- `|` – или (то, что слева, или то, что справа)
- `()` – группировка символов
- `[]` – любой единичный символ из заключенных в скобки
- `[^]` – любой единичный символ, кроме заключенных в скобки
- NB: внутри `[]` не работают операторы `.` `\` `*` `+` и т. д.

Выбор и группировка СИМВОЛОВ

- () – группа символов/слов, может употребляться в любой части слова
 - аха(ха)?, аха(ха)*, аха(ха)+
 - еще (много)? раз, еще (много)* раз, еще (много)+ раз
- | – или (разделение вариантов), может употребляться в любой части слова
 - риэлте|о|эр, риэлт(е|о|э)р, ри(е|э)лт(е|о|э)р
 - (пере|недо|за)(пил|ел|жил)
- регулярное выражение, которое сопоставится со строками
 - *сносно, совсем, список, способ, сенсор*
 - *дедушка, прадедушка, прапрадедушка, прапрапрадедушка*
 - *дедушка, бабушка, прадедушка, прабабушка, прапрадедушка, прапрабабушка, прапрапрадедушка, прапрапрабабушка*
 - *один или более раз повторяется кусь, или гусь, или учусь (можно комбинировать слова)*

Классы (диапазоны) СИМВОЛОВ

- [A-Z] или [[:upper:]] – любой символ верхнего регистра (латиница)
- [a-z] или [[:lower:]] – любой символ нижнего регистра (латиница)
- [А-ЯЁ] или [[:upper:]] – любой символ верхнего регистра (кириллица)
- [а-яё] или [[:lower:]] – любой символ нижнего регистра (кириллица)
- [A-Za-z] или [[:alpha:]] – любой символ верхнего или нижнего регистра (латиница)
- [А-ЯЁа-яё] или [[:alpha:]] – любой символ верхнего или нижнего регистра (кириллица)
- [A-ZА-ЯЁ] – любая кириллическая или латинская буква верхнего регистра
- [a-za-яё] – любая кириллическая или латинская буква нижнего регистра
- [A-ZА-ЯЁа-za-яё] – любая кириллическая или латинская буква верхнего или нижнего регистра
- можно выбрать нужный диапазон из [таблицы Unicode](#) самостоятельно

Классы (диапазоны) СИМВОЛОВ

- [0-9], или [[:digit:]], или \d – цифра
- [A-Z0-9] – любой символ верхнего регистра (латиница) или цифра
- [a-z0-9] – любой символ нижнего регистра (латиница) или цифра
- [А-ЯЁ0-9] – любой символ верхнего регистра (кириллица) или цифра
- [а-яё0-9] – любой символ нижнего регистра (кириллица) или цифра
- [A-Za-z0-9] или [[:alnum:]] – любой символ верхнего или нижнего регистра (латиница) или цифра
- [А-ЯЁа-яё0-9] или [[:alnum:]] – любой символ верхнего или нижнего регистра (кириллица) или цифра
- [A-Za-z0-9_] или \w – любой символ верхнего или нижнего регистра (латиница), или цифра, или знак _
- [А-ЯЁа-яё0-9_] или \w – любой символ верхнего или нижнего регистра (кириллица), или цифра, или знак _
- [[:punct:]] – символ пунктуации, [[:space:]] или \s – пробельный символ

Классы (диапазоны) СИМВОЛОВ

- регулярное выражение, которое сопоставится
 - со строками вида *ГБОУ Школа трех- или четырехзначное число*
 - со строкой вида *одна кириллическая буква в верхнем регистре, ноль или более кириллических букв в нижнем регистре, пробел, одна кириллическая буква в верхнем регистре, одна или более кириллических букв в нижнем регистре, пробел, цифра 8 и потом любое количество любых цифр*

Произвольные классы (диапазоны) символов


- [] – ваш собственный класс символов, [abc] аналогично (a|b|c)
 - в[ыйоа]л, [впнмт]ыл, ныл[аои]?
 - 20[3-6]год, господин [А-ЯЁ][а-яё]+
- регулярное выражение, которое сопоставится со строками вида
 - *после маленькой кириллической буквы стоит точка, восклицательный знак или вопросительный знак, потом пробел и большая кириллическая буква*

Инвертированные классы (диапазоны) символов

- `[^ ]` – инвертированный класс (все кроме этих символов)
 - `гр[^её]б, [^пнг]ик`
 - `[^\d]+` рублей, `[^\w]` юаней
- `[^0-9]`, или `[^[:digit:]]`, или `\D` – любой символ, кроме цифры
- `[^A-Za-z]` или `[^[:alpha:]]` – все, кроме символов верхнего и нижнего регистра (латиница)
- `[^А-ЯЁа-яё]` или `[^[:alpha:]]` – все, кроме символов верхнего и нижнего регистра (кириллица)
- `[^A-Za-z0-9]` или `[^[:alnum:]]` – все, кроме символов верхнего и нижнего регистра (латиница) и цифр
- `[^А-ЯЁа-яё0-9]` или `[^[:alnum:]]` – все, кроме символов верхнего и нижнего регистра (кириллица) и цифр
- `[^A-Za-z0-9_]` или `\W` – все, кроме символов верхнего и нижнего регистра (латиница), цифр и знака `_`
- `[^А-ЯЁа-яё0-9_]` или `\W` – все, кроме символов верхнего и нижнего регистра (кириллица), цифр и знака `_`

Служебные символы

- `\s` – любой пробельный символ
- `\S` – любой непробельный символ
- `\w` – любое слово, цифра или знак `_`
- `\W` – не слово, цифра или знак `_`
- `\d` – цифра
- `\D` – любой символ, кроме цифры
- `\b` – граница слова
- `\B` – не граница слова
- `^` – начало строки
- `$` – конец строки
- `\t` – табуляция
- `\n` (`\r\n` на Windows) – перенос строки




CommitStrip.com

Экранирование метасимволов

- как и любой язык, регулярные выражения записываются с помощью особого алфавита – точек, астерисков, скобок и т.д.
- что делать, если нужно найти метасимволы вроде + или * в тексте?
- все просто: нужно экранировать их, т.е. поставить перед ними знак \
- регулярное выражение, которое сопоставится с
 - датами вида ДД.ММ.ГГГГ, но при этом не найдет просто последовательности цифр
 - названиями сайтов в доменной зоне .ru
 - строкой вида (текст любой длины)

WHAT GIVES PEOPLE FEELINGS OF POWER



Приключения Кьеркегора

REGULAR EXPRESSION8 matches, 142 steps (~23ms)

`ir" Кь?(е|и)ркег(о|аа)рд?[^\s\.,\?!:;-]{,2}`" g

TEST STRINGSWITCH TO UNIT TESTS ▶

Киркегор - датский философ, богослов и писатель, один из предшественников экзистенциализма.

С. Кьеркегор окончил теологический факультет Копенгагенского университета в 1840 году. Степень магистра получил в 1841 году, защитив диссертацию «О понятии иронии, с постоянным обращением к Сократу», посвященную концепциям иронии у древнегреческих авторов и романтиков. Работы С. Кьеркегора отличаются исключительной психологической точностью и глубиной. Вклад в развитие философии, сделанный Кьеркегаардом, неocenim.

Сёрен Киркегаард: Немецкое Издание Сёрена Киркегаарда.

Спецкурс «С. Керкегор и история христианства в XIX в.» посвящен датскому философу Серену Керкегору.

Приключения Кьеркегора

- К – соответствует заглавной букве "К" (строчную "к" ловить не будет)
- ь? – мягкий знак может быть, а может не быть
- (е|и) – дальше может быть либо "е", либо "и"; если скобки не поставить, то выбор будет не только между двумя буквами, а между подстрокой до знака | и подстрокой после знака |
- ркег – ищет соответствующую последовательность
- (о|аа) – дальше может быть либо "о", либо "аа"
- р – просто "р"
- д? – "д" может быть, а может не быть
- [^\s,?!:;-] – дальше может идти любой знак кроме пробела и знаков пунктуации (это нужно, чтобы найти Кьеркегора во всех падежах)
- {2} – предыдущее выражение может встречаться от 0 (И.п. "Кьеркегор") до 2 (Т.п. "Кьеркегором") раз

Язык корпусных запросов (Corpus Query Language)

- специальный язык запросов для
 - поиска сложных грамматических или лексических шаблонов использования критериев поиска, которые невозможно установить с помощью стандартного интерфейса
- используется при установке критериев для отдельных позиций или токенов (словоформ, лемм, тегов и т. д.)
- основывается на синтаксисе регулярных выражений, немного отличается в разных корпусах (могут работать не все операторы или атрибуты, некоторые операторы могут иметь разное значение в разных корпусах и т. п., см. [условия поиска с регулярными выражениями в НКРЯ](#))
- разработан [исследовательской группой Textcorpora and Lexicon Института обработки естественного языка Штутгартского университета](#) в начале 1990-х годов



```
(?:[a-z0-9!#$%&'*/+=?^_`{|}~-]+(?:\. [a-z0-9!#$%&'*/+=?^_`{|}~-]+)*"?:[\x01-\x08\x0b\x0c\x0e-\x1f\x21\x23-\x5b\x5d-\x7f]|\[[\x01-\x09\x0b\x0c\x0e-\x7f]*\])@(?: (?:[a-z0-9](?:[a-z0-9-]*[a-z0-9])?\.)+[a-z0-9](?:[a-z0-9-]*[a-z0-9])?)|[(?:25[0-5]|2[0-4][0-9]|[01]?[0-9][0-9]?)\.]{3}(?:25[0-5]|2[0-4][0-9]|[01]?[0-9][0-9]?)?[a-z0-9-]*[a-z0-9](?:[\x01-\x08\x0b\x0c\x0e-\x1f\x21-\x5a\x53-\x7f]|\[[\x01-\x09\x0b\x0c\x0e-\x7f]\])+)\)
```

Базовый синтаксис CQL

- общая схема запроса – [атрибут="значение"]
- основные атрибуты – lemma, word, tag
- = – равно, != – не равно
 - [lemma="чесать"][lemma="толстый"][lemma="кот"]
 - [word = "чешу"][word = "толстого"][word != "кота"]
 - [tag="V.*"][tag="A.*"][tag="N.*"]
- пробелы между атрибутами и операторами обычно ничего не означают, пробелы внутри значений атрибутов обозначают сами себя
 - [lemma = "чесать"] [lemma = "толстый"] [lemma= "кот"]
 - [lemma="жирный "] [lemma=" мопс"]
 - [word="заяц"][lemma="грызть"][tag="N.*"]

Базовый синтаксис CQL

- `[ ]` – произвольный токен
- `? * + { }` – количество повторений токена
- `[ ]{m,n}` – расстояние между токенами в запросе
 - `[lemma="супер.*"], [lemma=".+завр"], [lemma="л.?к"]`
 - `[lemma="пить"] [ ] [lemma="чай"]`
 - `[lemma="иметь"] [ ]{2,4} [lemma="мнение"]`
 - `[lemma="налить"] [tag="А.*"]{2} [lemma="вода"]`
 - `[lemma="съесть"] [lemma="этот"]? [lemma="вкусный"] [lemma="булка"]` аналогично `[lemma="съесть"] [lemma="этот"]{0,1} [lemma="вкусный"] [lemma="булка"]`

Базовый синтаксис CQL

- конъюнкция обозначается знаком &
 - [word="пыли" & tag="N.*"]
 - [lemma = "течь" & tag != "V.*"] аналогично [lemma="течь" & !tag="V.*"]
 - [word="вой" & (tag="N.*" | tag="V.*")]
- дизъюнкция обозначается знаком |
 - [lemma="карась"] | [lemma="гусь"] аналогично [lemma="карась|гусь"]
 - [tag="A.*"] | [lemma="стул"] аналогично [tag="A.*" | lemma="стул"]
 - ([lemma="большой"][lemma="собака"]) | [lemma="волк"]

Базовый синтаксис CQL

- по умолчанию регулярные выражения учитывают регистр, чтобы это изменить, в начале надо поставить (?i) – действие этого оператора распространяется на все последующее выражение
 - [word="(?i)c"] [word="(?i)днем"] [word="(?i)рождения"]
- условие «токен/тег не начинается с» задается через ?! перед отрицаемым выражением, вся отрицательная конструкция берется в скобки, за скобками должно следовать регулярное выражение, описывающее состав токена или тега
 - [tag="(!N).*"], [lemma="(!c)..."]
- экранирование символов делается через \ или ==
 - [word="\."] аналогично [word=="."]

NB: даже при использовании == или != необходимо экранировать знаки " " и \

Метаразметка

A corpus with structures and values

```
<doc id="20110658A" pub="1970" lang="en">
  <p style = "formal">
    <s><pers gender="female">Rebecca</pers> has worked with a full range of clients including <brand sect="automoti
    <s> She showed her attention to detail and overall competence.</s>
  </p>
  <p style = "informal">
    <s>I remember her first day at work where she knocked her coffe over spilt it over documents.</s>
    <s>Such fun!</s>
  </p>
</doc>
<doc pub="1977">
  <p style = "informal">
    <s>first sentence</s>
    <s>second sentence</s>
  </p>
  <p style = "informal">
    <s>third sentence </s>
    <s>fourth sentence</s>
  </p>
</doc>
```



Поиск по структурным элементам

- основные структурные элементы – doc (документ), p (абзац), s (предложение)
- начало структурного элемента <s> <p> <doc> etc.
- конец структурного элемента </s> </p> </doc> etc.
- весь структурный элемент < s/> < p/> < doc/> etc.
 - <doc style="informal">[lemma="псина"]
 - <doc pub="2011"> [tag="N.*"] []{0,5} [tag="V.*"]
 - <doc lang="ru" & type="written"> [tag="N.*"] []{0,5} [tag="V.*"]
 - [tag="V.*"] within <doc style="informal" />

Операторы **within** и **containing**

- поиск в CQL не учитывает автоматически структурные элементы корпуса, поэтому легко могут возникнуть ситуации, когда части интересующей нас конструкции оказываются на стыке предложений и т. п.
- используются для ограничения поиска только
 - определенным структурным элементом корпуса: для поиска внутри предложения, абзаца, документа и т. д.
 - грамматической или лексической структурой: именной группой, выражением «чем раньше... тем больше...» и т. д.

Операторы `within` и `containing`

- ищут токен(ы) внутри структуры, разница заключается в том, каков результат, т. е. что выделено в конкордансе как KWIC:
 - при использовании `within` – слово или фраза,
 - при использовании `containing` – вся структура
- отрицание обозначается знаком `!` перед оператором
 - `"dog" []{0,5} "runs" within < s/>`
 - `[tag="N.*"] within [tag="VB.*"] []{0,5} [tag="VB.*"]` аналогично `"N.*" within "VB.*" []{0,5} "VB.*"`
 - `"N.*" within ("VB.*" []{0,5} "VB.*" within < s/>)`
 - `< p/> containing [word="[A-Z]{3,}"]`
 - `[tag="J.*"]{1,5} [tag="N.*"] containing [word="international"]`
 - `[tag="N.*"] !within < nphr/>` аналогично `"N.*" !within < nphr/>`
 - `< s/> !containing [word="[A-Z][A-Za-z]*"]`

Операторы meet и union

- одновременный поиск по левому и правому контекстам возможен только с помощью этих операторов: стандартный CQL позволяет выполнять поиск только в левом или правом контексте, но не в обоих одновременно
 - (meet [tag = "N.*"] [tag = "VB.*"] -3 3)
 - (union (meet [tag="N.*"] [tag="VB.*"] -3 3) (meet [tag="A.*"] [tag="VB.*"] -2 2))
 - (union(meet [tag="N.*"] [lemma="competent"] -2 -1)(meet [tag="J.*"] [lemma="competence"] 1 2))
 - < s/> containing (meet [lemma="have"] [tag="P.*"] -3 5) containing (meet [tag="N.*"] [lemma="blue"] -4 2)

Поиск с глобальным условием (global condition)

- используется для сравнения токенов между собой и для установки дополнительных параметров для отдельных токенов
- токены должны быть помечены, чтобы для них можно было установить глобальные условия, для использования в условии можно пометить более одной позиции
- метка – это цифра (или буква), за которой следует двоеточие, например 2:[] или b:[]
- условие для сравнения необходимо добавить в самый конец запроса после знака & (или выражения with equal)
- общая схема запроса – 1:[] 2:[] & 1.атрибут = 2.атрибут или a:[] b:[] with equal (a. атрибут, b. атрибут), при использовании containing или within лучше брать запрос в скобки
 - 1:[] 2:[] [] {3,10} 3:[] & 1.tag = 2.tag & 3.lemma=1.lemma
 - (1:[tag="N.*"] [] {0,3} 2:[tag="V.*"] within < s/>) & 1.lemma=2.lemma & 1.lc!=2.lc
 - 1: [] 2: [] & f(1.lemma)>10000 & f(2.lemma)<50

Araneum Russicum

- веб-корпус русского языка, созданный в 2016 г. в Братиславе группой исследователей во главе со словацким компьютерным лингвистом Владимиром Бенко
- собран посредством обкачивания Интернет-ресурсов на соответствующих языках
- в качестве поисковой системы используется корпусный движок NoSketchEngine, созданный в лаборатории обработки естественного языка факультета информатики Масарикова университета в Брно



[Home](#)[Search](#)[Word list](#)[Corpus info](#)[My jobs](#)[User guide](#)

Corpus: Araneum Russicum III Minus (Russian, 19.03) 125 M

Simple query: [Query types](#) [Context](#) [Text types](#) Query type ☒ simple ☐ lemma ☐ phrase ☐ word ☐ character ☐ CQLLemma: PoS: unspecifiedPhrase: Word form: PoS: unspecified ☐ match caseCharacter: CQL: Default attribute: word[Tagset summary](#) [CQL builder](#)

Разметка для русского языка

P	Attribute (en)	Value (en)	Code (en)
0	CATEGORY	Noun	N
1	Type	common	c
		proper	p
2	Gender	masculine	m
		feminine	f
		neuter	n
		common	c
3	Number	singular	s
		plural	p
4	Case	nominative	n
		genitive	g
		dative	d
		accusative	a
		vocative	v
		locative	l
		instrumental	i
5	Animate	no	n
		yes	y
6	Case2	partitive	p
		locative	l

P	Attribute (en)	Value (en)	Code (en)
0	CATEGORY	Adjective	A
1	Type	qualificative	f
		possessive	s
2	Degree	positive	p
		comparative	c
		superlative	s
3	Gender	masculine	m
		feminine	f
		neuter	n
4	Number	singular	s
		plural	p
5	Case	nominative	n
		genitive	g
		dative	d
		accusative	a
		locative	l
		instrumental	i
6	Definiteness	short-art	s
		full-art	f

P	Attribute (en)	Value (en)	Code (en)
0	CATEGORY	Pronoun	P
1	Type	personal	p
		demonstrative	d
		indefinite	i
		possessive	s
		interrogative	q
		relative	r
		reflexive	x
		negative	z
		nonspecific	n
2	Person	first	1
		second	2
		third	3
3	Gender	masculine	m
		feminine	f
		neuter	n
4	Number	singular	s
		plural	p
5	Case	nominative	n
		genitive	g
		dative	d
		accusative	a
		vocative	v
		locative	l
		instrumental	i
6	Syntactic_Type	nominal	n
		adjectival	a
		adverbial	r
7	Animate	no	n
		yes	y

Araneum Russicum

- поиск слова / леммы по началу или концу, по началу и концу одновременно

Araneum Russicum

- поиск слова / леммы по началу или концу, по началу и концу одновременно
- [lemma="пол.*"], [word=".*ент"], [lemma="пере.*ик"]

Araneum Russicum

- поиск слова / леммы по набору грамматических признаков (все прилагательные в сравнительной степени / все числительные в дательном или предложном падеже)

Araneum Russicum

- поиск слова / леммы по набору грамматических признаков (все прилагательные в сравнительной степени / все числительные в дательном или предложном падеже)
- [tag="A.c.*"], [tag="M...[dl].*"] или [tag="M...(d|l).*"]

Araneum Russicum

- поиск конкретного слова / леммы с определенным набором грамматических признаков (сравнительные степени наречий на по- / мой как глагол в повелительном наклонении)

Araneum Russicum

- поиск конкретного слова / леммы с определенным набором грамматических признаков (сравнительные степени наречий на по- / мой как глагол в повелительном наклонении)
- [lemma="по.*" & tag="Rc"], [word="мой" & tag="V.m.*"]

Araneum Russicum

- поиск сочетания прилагательного, оканчивающегося на –ский / -ный, и существительного с приставкой макси- / гипер-

Araneum Russicum

- поиск сочетания прилагательного, оканчивающегося на -ский / -ный, и существительного с приставкой макси- / гипер-
- [lemma="*.ский"] [lemma="макси.*"], [lemma="*.ный"] [lemma="гипер.*"]

Araneum Russicum

- поиск словосочетания с разными вариантами входящих в него лексем (жирный или толстый + кот / преподаватель + глагол в прошедшем или будущем времени)

Araneum Russicum

- поиск словосочетания с разными вариантами входящих в него лексем (жирный или толстый + кот / преподаватель или преподавательница + глагол в прошедшем или будущем времени)
- [lemma="жирный|толстый"] [lemma="кот"], [lemma="преподаватель"] [tag="V..[fs].*"]
или [lemma="преподаватель(ница)?"] [tag="V..(f|s).*"]

Araneum Russicum

- поиск с интервалом между словами (количественное числительное в именительном падеже + существительное в именительном падеже, между которыми находится от 1 до 3 слов)

Araneum Russicum

- поиск с интервалом между словами (количественное числительное в именительном падеже + существительное в именительном падеже, между которыми находится от 1 до 3 слов)
- [tag="М...n.*"] []{1,3} [tag="N...n.*"]


Voyant Tools

- [Voyant Tools](#) – веб-приложение для анализа текста, который можно ввести, загрузить из файла (поддерживает форматы DOC, TXT, HTML, XML, PDF, RTF), нескольких файлов или по ссылке
- сочетает в себе множество базовых инструментов для текстового анализа и работы с пользовательским корпусом (составление частотных списков слов, выделение ключевых слов в документах, тематическое моделирование, нахождение коллокаций, расчет статистики по документам, построение графиков и облаков слов и т.д.)
- [подробный гайд по работе с Voyant Tools](#)
- [скринкаст по работе с Voyant Tools](#)
- [видеоинструкция по использованию разных инструментов Voyant Tools](#)



Работа с Voyant Tools


- Тексты каждого изучаемого периода/жанра/автора и т.д. лучше представить в одинаковом объеме или отфильтровать по определенному признаку
- Название файла удобно делать однотипными, например, начинать с года – так в Voyant Tools будет удобно отследить изменение во времени
- Русскоязычный корпус перед исследованием лучше лемматизировать (в случае, если вы не будете изучать грамматические признаки)
- Имеются встроенные списки стоп-слов для многих языков, но можно задать или дополнить их самостоятельно
- Поиск на всех панелях поддерживает один и тот же поисковый синтаксис





1590 Love's Labour's Lost

LOVE'S LABOUR'S LOST
 DRAMATIS PERSONAE
 FERDINAND king of Navarre.
 BIRON |
 LONGAVILLE | lords attending on the King.
 DU MAINE |

Scale Terms:

This corpus has 37 documents with 895,737 total words and 25,114 unique word forms. Created about 2 years ago.

Document Length:

- Longest: 1599 Hamlet (32396); 1593 King Richard III (31846); 1608 Coriolanus (29485); 1610 Cymbeline (29204); 1597 King Henry IV (Part... (28225)
- Shortest: 1591 Comedy of Errors (16339); 1594 Midsummer Night's... (17332); 1611 Tempest (17582); 1605 Macbeth (18414); 1591 Two Gentlemen of... (18443)

items:


Document	Left	Term	Right
1) 1590 ...	may buy That honour which	shall	bate his scythe's keen edge
1) 1590 ...	world's desires,-- Our late edict	shall	strongly stand in force: Navarre
1) 1590 ...	strongly stand in force: Navarre	shall	be the wonder of the
1) 1590 ...	of the world; Our court	shall	be a little Academe, Still
1) 1590 ...	three years' fast: The mind	shall	banquet. though the body pine
3,594 context expand Scale			

AntConc

- [AntConc](#) – программа для поиска и подсчета различных элементов текста, анализа частотности и контекста употребления словоформ, словосочетаний и морфем, сравнения употребительности словоформ в разных текстах
- отсутствие морфологического анализатора частично компенсируется возможностью подключения пользовательского списка лемм
- программа может быть использована для получения привязанных к заданной предметной области словарных минимумов, списков устойчивых сочетаний (в том числе терминологических), выборок к тематическим группам слов
- [видеотutorial от автора по работе в AntConc](#)
- [A Simple Guide to Using Antconc](#)
- [AntConc Help](#)
- [пример использования для анализа текстов](#)

Работа с AntConc

- Чтобы загрузить файл, в меню File нажимаем «Open File» (файл должен быть в формате .txt / .xml / .html)
- Открываем во второй сверху строке меню кнопку «Word List» и нажимаем кнопку «Start». Программа выстроит все словоформы текста в порядке частотности
- Если кликнуть любое слово из списка, начнется его автоматический поиск в окне Concordance
- Можно использовать следующие специальные символы



Target Corpus

Name: AmE06_Learned

Files: 80

Tokens: 161469

AmE06_J01.txt

AmE06_J02.txt

AmE06_J03.txt

AmE06_J04.txt

AmE06_J05.txt

AmE06_J06.txt

AmE06_J07.txt

AmE06_J08.txt

AmE06_J09.txt

AmE06_J10.txt

AmE06_J11.txt

AmE06_J12.txt

AmE06_J13.txt

AmE06_J14.txt

AmE06_J15.txt

AmE06_J16.txt

AmE06_J17.txt

AmE06_J18.txt

AmE06_J19.txt

AmE06_J20.txt

AmE06_J21.txt

Progress 100%

KWIC Plot File View Cluster N-Gram Collocate Word Keyword Wordcloud

Total Hits: 87 Page Size 100 hits 1 to 87 of 87 hits

	File	Left Context	Hit	Right Context
1	AmE...	It is, however, prompted by the need to place the	process	of taking moments in context. Moments of the Distribution
2	AmE...	f online distance education. Successful online teaching is a	process	of taking our very best practices in the classroom
3	AmE...	in their parents' homes. The findings demonstrate that the	process	of assimilation was not uniform for all groups. Some
4	AmE...	with the Communist Party of Indonesia, which was in the	process	of being eliminated by Soeharto's New Order government.
5	AmE...	acred texts," the canon of modern children's literature. The	process	of creating or augmenting professional identity relied partic
6	AmE...	eyes, you lack that protein. Now scientists are in the	process	of figuring out which proteins are coded for by
7	AmE...	(2004), Donlan and Martin (2004), and Pysek et al. (2004).	Process	of invasion At one level, the issue of invasive
8	AmE...	or and the other participants is formed, through which the	process	of knowledge acquisition is collaboratively created. (See Ch
9	AmE...	express an inference. An inference , in turn, is a mental	process	of linking propositions by offering support to one propositi
10	AmE...	een theoretically appropriate for explaining the adaptation	process	of newcomers who arrived in America in the early 20
11	AmE...	motoric instructions, either unmodified or modified by the	process	of overlap. We postulate a parallel language-specific proces
12	AmE...	asured confounding is accounting for the findings, as the	process	of randomization makes the mathematical probability of su
13	AmE...	nt residue of mantle differentiation including the on-going	process	of seafloor spreading and building of island arcs. It
14	AmE...	ikszentmihalyi's (1990) concept of "flow" is a more general	process	of self-actualization. In flow, a person's tasks
15	AmE...	a voice of "several strengths." Her voice thereby enacts a	process	of the black community speaking to itself and explores
16	AmE...	is not it is that the critical thinker takes the	process	of thinking seriously consciously attends to that process an


Search Query ☒ Words ☐ Case ☐ Regex Results Set All hits Context Size 10 token(s)process Start ☐ Adv Search

Sort Options Sort to right Sort 1 1R Sort 2 2R Sort 3 3R Order by freq

Time taken (creating kwic results): 0.3314 sec

LancsBox X



- [LancsBox X](#) – корпусный менеджер для работы с собственными языковыми данными и визуализации результатов исследования
- анализирует данные на любом языке, для некоторых языков доступна функция автоматической морфологической и семантической разметки
- строит динамические графы коллокаций по разным мерам ассоциации, облака слов с учетом частотности и дисперсии
- [видеотutorial по работе с LancsBox X](#)
- [инструкция по работе с LancsBox X](#)
- [вебинар об использовании LancsBox X](#)



Searched Words table for "new".

Регулярные выражения

- Теория и упражнения
 - <https://regexone.com>
 - <https://regexr.com>
 - <https://regex101.com>
 - <https://www.regular-expressions.info>
 - <https://regexlearn.com>
 - <https://regexcrossword.com>
- [Шпаргалка по регулярным выражениям](#)
- [Основы регулярных выражений](#)
- [Регулярные выражения на CQL](#)
- [Инструкция по использованию CQL](#)
- [Общая информация о регулярных выражениях в корпусных запросах](#)



Списки корпусов

- <https://linghub.ru>
- <https://ruscorpora.ru/page/corpora-other>
- <https://lremap.elra.info>
- <https://www.clarin.eu/resource-families>
- <https://catalog.ldc.upenn.edu>
- <https://metashare.csc.fi/repository/search/>
- <https://www.corpusfinder.ugent.be/corpora>
- https://aclweb.org/aclwiki/List_of_resources_by_language
- <http://www.elra.info/en/catalogues/catalogue-language-resources/>



Веб-корпуса

- [Taiga Corpus](#)
- [Omnia Russica](#)
- [Aranea web corpora](#)
- [TenTen web corpora](#)
- [WaCKy corpora](#)
- [CommonCrawl](#)
- [OSCAR Project](#)
- [ParaCrawl Corpus](#)
- [MaCoCu Corpora](#)
- [CLARIN.SI web corpora \(old interface\)](#)
- [GeoWAC](#)
- [Corpus of Global Language Use](#)
- [University of Leeds web corpora](#)
- [No Language Left Behind](#)
- [Open Parallel Corpus](#)
- [Open Language Data Initiative](#)
- [Hamburg Center for Language Corpora](#)
- [Universal Dependencies](#)



Корпусные менеджеры

- [Voyant Tools](#)
- [AntConc](#)
- [LancsBox X \(old version\)](#)
- [Sketch Engine](#)
- [NoSketch Engine](#)
- [CQPweb](#)
- [IMS Open Corpus Workbench](#)
- [EXMARaLDA](#)
- [WordSmith Tools](#)
- [ANNIS](#)
- [ParaConc](#)
- [XAIRA](#)
- [MonoConc](#)
- [Wmatrix](#)
- [Tsakorpus](#)
- [SpoCo](#)
- [Korp](#)
- [TXM](#)

